

면접 질문·답변 통합본 (한국어 + English)

구성: ① 수학기획서 핵심 정리 → ② 질문 · 답변(한국어) · 답변(English) → ③ 영어 한 줄 설명 → ④ 용어 정리(영문명 포함) · [] = 직접 확인해서 채울 부분 · 노란색 = 가장 중요

말하기 팁

· 외우지 말고 첫 문장 + 키워드만 기억하세요. 매번 똑같이 말할 필요 없습니다.

· 문장이 길어지면 끊어서, 숨 쉬고, 천천히. 면접관은 속도가 아니라 내용을 봅니다.

· 모르는 건 "아직 확인하지 못했는데, 제가 이해한 바로는..."으로 아는 데까지만 말하고 마무리하세요.

· []는 실제로 확인하거나 해본 것만 넣으세요. 안 해본 것을 말하면 꼬리질문에서 막힙니다.

영어 답변 팁 (English tips)

· 짧은 문장, 천천히. 완벽한 발음은 필요 없습니다. 첫 문장 + 키워드 3개만 기억하세요.

· 유용한 표현: "Could you please repeat the question?" / "Let me organize my thoughts for a moment." / "I haven't confirmed that yet, but my understanding is ..." / "I'd like to discuss that with you if I'm admitted."

· 교수님이 한국어로 물으면 한국어로, 영어로 물으면 영어로 답하세요. 한국어 문장 안에 영어 전문용어를 섞어도 괜찮습니다.

0. 제출한 수학(연구)계획서 핵심 정리 (이 내용에서 질문이 나옵니다)

교수님은 이 계획서를 처음 보시는 상황입니다. 지원서에 쓴 모든 문장은 질문이 될 수 있다고 생각하고, 아래 표를 소리 내어 읽어 보세요.

0-1. 한 장 요약	
항목	지원서에 쓴 내용 → 면접용 정리
지원 단위·희망 분야	식사과정 농생명공학부 바이오모듈레이션전공 · 희망전공분야: 생물정보 및 집단유전학 (bioinformatics & population genetics)
희망 연구	국내 멸종위기종 유전체를 재분석해 유전다양성(genetic diversity)과 근친 정도(inbreeding)를 평가하고, 종복원 정책에 쓸 근거자료 마련
문제의식	천연기념물·멸종위기종이 여럿이지만 유전체 수준 연구는 부족. 공개 재서열 데이터가 있어도 가까운 참조유전체가 없어 먼 종에 맞춰 분석한 사례가 있음
기회	최근 염색체 수준 참조유전체가 늘어 기존 공개 데이터를 새 참조에 재매핑해 정밀 분석 가능. 새 시료 채집·시퀀싱 없이 진행
우선 대상	산양(Naemorhedus caudatus): 멸종위기 I급·천연기념물 217호, 서식지 단절로 고립·유전다양성 감소 우려. 2024년 같은 속 히말라야산양(N. goral)의 염색체 수준 참조 구축. 범위는 개체 수·심도 확인 후 교수님과 논의해 확정
랩과의 연결	이 분석 흐름이 랩의 아프리카 토착 소 기원 연구 방법론과 유사하다고 서술 (△ 어느 부분이 유사한지 말할 수 있어야 함. 확인 못 했으면 "분석 흐름이 비슷하다고 이해한다"까지)
결론	유전다양성·근친 수준·과거 개체군 변동을 유전체 수준에서 평가 → 개체군 관리·복원 기초자료. 방법론을 다른 멸종위기종으로 확장
석사·박사 이후	장기: 멸종위기종 복원 연구자. 학위과정은 훈련 과정, 석·박 모두 열린 마음. 취업 시 국립생태원·국립생물자원관, 관련 자격증·어학 준비

0-2. 방법론 6단계 (쉽게 설명)

한 문장으로: 이미 읽어 둔 산양 DNA 조각을 새로 나온 "정답 지도"에 맞춰 붙이고, 지도와 다른 글자를 찾은 뒤, 그 글자들의 패턴으로 다양성 · 근친 · 과거 개체수를 읽어낸다.

책 복원 비유로 이해하기

- 산양 한 마리의 DNA = 두꺼운 책 한 권(약 26억 글자). 시퀀싱 기계는 이 책을 잘게 찢어서 조각(리드) 수억 개를 읽어 줍니다.
- 참조유전체 = 같은 종류 책의 정답본. 가까운 종의 정답본일수록 조각이 잘 맞습니다.
- 우리가 하는 일 = ① 조각을 받아서 ② 지저분한 조각을 버리고 ③ 정답본의 어느 쪽인지 찾아 붙인 뒤 ④ 정답본과 다른 글자를 표시하고 ⑤⑥ 그 표시들의 패턴을 해석합니다.

#	단계 (English · 도구)	쉬운 비유	넣는 것 → 나오는 것	왜 필요한가	면접용 한 문장
①	데이터 확보 Data retrieval · NCBI SRA	도서관(NCBI)에서 찢어진 책 조각 파일 내려받기	접근번호(PRJNA361026) → FASTQ 파일	새로 시퀀싱하지 않아도 연구 가능	"공개된 산양 재서열 데이터를 내려받습니다."
②	품질관리 Quality control · fastp	잉크가 번졌거나 표지가 섞인 조각 골라 버리기	FASTQ → 깨끗한 FASTQ	오류가 많으면 가짜 변이가 생김	"오류가 많은 구간을 걸러냅니다."
③	매핑 Read mapping · BWA-MEM	조각을 정답본의 알맞은 쪽에 퍼즐처럼 붙이기	깨끗한 조각 + 참조 → BAM	위치를 알아야 비교 가능. 참조가 가까울수록 잘 맞음	"새 참조에 읽은 조각을 정렬합니다."
④	변이 호출 Variant calling · bcftools	같은 자리에 쌓인 조각들을 보고 "정답본과 다른 글자" 이탈자 표시	BAM → VCF(변이 목록)	다른 글자가 곧 개체의 유전 정보	"참조와 다른 지점, 변이를 찾습니다."
⑤	이형접합도 · ROH Heterozygosity · Runs of Homozygosity	VCF 표를 요약: 엄마-아빠 글자가 다른 자리의 비율 / 같은 구간이 길게 이어진 곳	VCF → 숫자(이형접합도), 구간 목록(ROH)	다양성과 근친 정도 평가	"이형접합도로 다양성을, ROH로 근친 정도를 봅니다."
⑥	개체군 역사 Demographic history · PSMC	DNA 속 나이테: 이형접합 자리의 분포로 옛날 개체군이 컸는지 작았는지 거꾸로 읽기	한 개체의 DNA → 시간별 개체군 크기 곡선	과거 병목과 감소 추세 확인	"과거 개체군 크기의 변화를 추정합니다."

숫자로 감 잡기

- 이형접합도 $0.00113 = 1,000\text{글자당 약 } 1.1\text{개가 엄마-아빠 사이에 다름 (개체의 다양성)}$
- 산양과 양 사이 차이 약 $2\% = 1,000\text{글자당 약 } 21\text{개가 다름 (참조와의 거리)}$
- "지도(양)와의 차이(21개)"가 "개체 안의 차이(1.1개)"보다 훨씬 크다. 그래서 먼 지도를 쓰면 작은 신호가 흐려질 수 있고, 이것이 참조 편향입니다.

이형접합 vs ROH 그림으로 보기 (엄마 쪽 / 아빠 쪽 같은 염색체 자리)

엄마 쪽: A T G C C A T G G A T T C A G G T A C

아빠 쪽: A T G C T A T G A A T T C A G G T A C

→ 굵은 글자 2곳이 서로 다름 = 이형접합 2곳

엄마 쪽: G A T T C A G C C A T T G A C G G A T C T A

아빠 쪽: G A T T C A G C C A T T G A C G G A T C T A

→ 전부 같고, 이런 구간이 길게 이어짐 = 동형접합 구간(ROH)

· 이 같은 구간이 길수록 부모 양쪽이 가까운 조상(최근 근친)에서 같은 조각을 받았다는 뜻 / 짧으면 먼 옛날 조상(세대가 지날수록 재조합으로 조각이 잘게 쪼개지기 때문)

· PSMC는 이 이형접합 자리가 유전체 어디에 얼마나 흩어져 있는지를 보고 "옛날 조상 집단이 컸는지 작았는지"를 거꾸로 추정합니다. 시간 환산에는 돌연변이율(μ)과 세대시간(g)이 필요합니다.

0-3. 관심과목 3개: 지원서에 쓴 말 + 복습 핵심 + 연구와의 연결

과목	지원서에 쓴 내용	복습 핵심 개념 (English)	연구와 연결 · 한 줄 답
유전학 Genetics	멘델 유전부터 분자 수준의 유전자 발현·조절까지 / 대립유전자 빈도가 세대를 거치며 변하는 방식, 근친교배의 결과를 배움 / 이형접합도·ROH는 이 개념을 개체군 단위로 확장한 것	· 멘델 법칙: 분리·독립 (Mendel's laws: segregation, independent assortment) · 하디-바인베르크 평형 (Hardy-Weinberg equilibrium) $p^2+2pq+q^2=1$ · 근친계수 F (inbreeding coefficient): 근친 시 이형접합 비율 = $2pq(1-F)$ · 유전자 부동 (genetic drift), 재조합 (recombination), 연관 (linkage) · 유전자 발현 조절: DNA → RNA → 단백질 (central dogma)	"근친이 늘면 이형접합이 줄고 동형접합이 늘어납니다. ROH는 그 동형접합이 연속된 구간이고, 재조합으로 쪼개지기 때문에 길이가 근친 시기를 알려줍니다."
유전체학 Genomics	서열분석·조립·주석의 흐름 / 시퀀싱 데이터가 만들어지는 방식과 NCBI 공개 DB 활용 / 공개 재서열 데이터를 참조에 매핑하고 변이를 호출하는 과정에 적용	· 시퀀싱 (sequencing, NGS): 짧은 리드/긴 리드 (short/long reads) · 조립 (assembly): contig → scaffold → 염색체 (chromosome-level, Hi-C) · 주석 (annotation): 유전자 예측·기능 부여 (gene prediction, functional annotation) · 공개 DB: NCBI SRA / GenBank · 참조 기반 재서열 vs de novo (reference-based resequencing vs de novo assembly)	"읽은 조각을 이어 붙여 염색체 수준 참조를 만들고(조립), 유전자 위치를 표시하는 게 주석입니다. 저는 이미 만들어진 참조에 개체 데이터를 맞춰 변이를 찾는 재서열 분석을 합니다."
생태학 Ecology	개체군·군집·생태계 수준에서 생물과 환경의 상호작용 / 서식지 단편화가 개체군 크기에 미치는 영향, 생물다양성 평가 / 유전체 결과를 보전 현장과 연결하는 데 필요한 시각	· 개체군·군집·생태계 (population, community, ecosystem) · 서식지 단편화 (habitat fragmentation) → 이동 제한·고립 → 유전자 흐름 감소 (gene flow ↓) · 생물다양성 3수준: 유전적·종·생태계 (genetic, species, ecosystem diversity) · 최소존속개체군 (minimum viable population), 유효 개체군 크기 N_e	"서식지가 쪼개지면 개체군이 고립되어 유전자 흐름이 줄고, 작은 집단에서 유전자 부동과 근친이 늘어 유전다양성이 감소합니다. 그래서 유전체 결과를 서식지 관리와 연결해서 해석하겠습니다."

준비: 세 과목 모두 "수업에서 실제로 기억나는 내용 한 가지"를 말할 수 있게 준비하세요. 위 표의 표현은 복습용이고, 실제 수업에서 배운 사례가 있으면 그것으로 바꾸는 편이 낫습니다. 1년 전 수업이라 잊은 것은 솔직하게 "복습 중입니다"라고 하셔도 됩니다.

0-4. 지원서 문장 중 질문이 나올 만한 곳

지원서 문장	준비할 답
"선행 연구로 NCBI에 공개된 재서열 데이터가 있음에도 가까운 참조가 없어 먼 종에 맞춰 분석"	Weber et al. 2018(프리프린트): 산양 1개체 27x, 양 Oar_v4.0 참조, 이형접합도 0.00113, PSMC 감소 추세 (PRJNA361026)
"공개 데이터의 개체 수와 심도를 확인한 뒤 확정"	확인한 범위에서 전장 데이터는 단일 개체 27x → 범위를 "개체 정밀 분석 + 참조 비교"로 조정
"새로운 시료 채집이나 시퀀싱 없이"	장점: 비용·허가·시간 절약. 한계: 개체 수가 정해져 있음 → 교수님과 개체 확대 논의
"랩의 아프리카 토착 소 기원 연구와 유사한 분석 흐름"	[논문 방법 확인] 확인 못 했으면 "집단유전학적 분석 흐름이 비슷하다고 이해한다"
"관련 자격증과 어학 성적을 준비하고 있다"	[현재 어학 성적·시험 계획] 말할 수 있게 준비
"산양은 서식지 단절에 따른 고립과 유전다양성 감소 우려가 큰 종"	전수원 2015: mtDNA 66개체, 북부-남부 Fst 0.282 → 단편화·고립의 근거

0-5. 산불 논문 핵심 정리 (내가 참여한 논문 · 실제 논문 기준)

서지: Youn Yeo-Chang, Se-Eum Lee, Soo-Jin Lee, Hyo-Rin Kim. <i>Human Activities and Wildfires: The Impact of Forest Roads, Trails, and Forest Management on Wildfire Occurrence</i> . Fire 2026, 9, 246. (내 역할은 지원서 기준: 방법 구상, 수집·전처리, 분석, 초고 작성, 시각화)
한 줄: 강원·경북 산불(2022~2025.8)을 1km 격자로 분석해, 임도·등산로·산림관리 같은 사람 요인이 산불 발생에 주는 영향을 로지스틱 회귀로 해석했다.

항목	내용
가설 3개	H1 임령·수종 구성이 산불에 영향 → 지지 / H2 조림지 관리(숙아베기 등)가 산불을 늘린다 → 기각(유의하지 않음) / H3 임도·등산로 확충이 산불 위험을 높인다 → 부분 지지(임도는 오히려 억제, 등산로는 증가 경향)
자료	1km×1km 격자. 산불 492건 → 주소 불명확·중복 제외 발생 격자 471개. 비발생 격자는 지역(영동·영서·경북)별로 층화 무작위 추출 1,000개 → 총 1,471개. 기상은 발생 전날(D-1) 자료, 비발생은 임의의 날. 정보공개청구로 산불 위치 자료 확보, 산림청 임상도·임도·등산로·산림관리(2015~2017) 자료 사용. QGIS, Python(scikit-learn, xgboost, statsmodels, shap)
변수 5그룹	기상(유효습도·최대풍속·강수량) / 임상(평균 임령·침엽수 비율·흉고직경급·임목밀도·수고) / 기반시설(임도 밀도·등산로 밀도·임도까지 거리·등산로까지 거리) / 산림관리(조림지 관리·천연림 관리·기타) / 계절
분석 5단계	① 가설 설정 → ② 자료·변수 구축 → ③ 변수 선택(VIF 기준 모델 vs Random Forest vs XGBoost 세 방식 비교) → ④ 추정·평가(Pseudo R ² , AUC, SHAP) → ⑤ 가설 검증과 정책 해석
최종 모델	세 방식 중 성능이 가장 좋은 Random Forest 상위 10개 변수로 최종 로지스틱 회귀. AUC 0.8001, McFadden Pseudo R ² 0.1950 (VIF만 쓴 기준 모델은 AUC 0.7494, Pseudo R ² 0.1505 → 설명력 약 1.3배). XGBoost는 AUC 0.7960, 상위 10개 중 9개가 RF와 겹침. 강수량을 유무(이진)로 바꿔도 결과 유지(AUC 0.806)
왜 로지스틱 회귀?	핵심 목적이 예측 정확도보다 사람 요인의 방향과 유의성 해석. 블랙박스 모델은 계수 수준의 해석이 어려워 산림청 산불위험예보 개선에 쓰기 어려움

변수	계수	오즈비	p값	해석
유효습도	-0.0713	0.931	<0.001	습도가 높을수록 산불 감소
침엽수 비율	1.4446	4.240	<0.001	침엽수 많을수록 산불 증가 (약 4.2배)
평균 임령	-2.8588	0.057	<0.001	숲이 늙을수록 산불 크게 감소. 날씨를 빼면 가장 강한 억제 요인
임도 밀도	-2.7202	0.066	0.006	임도가 많을수록 산불 감소 (빠른 진화 접근)

등산로 밀도	1.4625	4.317	0.094	등산로가 많을수록 산불 증가 경향 (10% 수준)
강수량	-0.1881	0.829	0.005	비 올수록 감소
조림지 관리	0.0501	1.051	0.954	유의하지 않음 → 후속 연구 필요
임도·등산로까지 거리, 최대 풍속	-	-	0.68 / 0.11 / 0.74	유의하지 않음

▲ 꼭 바로잡기: "임도와 등산로 모두 가까울수록 산불이 억제된다"가 아닙니다. 논문 결과는 임도 밀도 ↑ → 산불 ↓, 등산로 밀도 ↑ → 산불 위험 ↑ (경향)입니다. 또 "가까움(거리)" 변수는 유의하지 않았습니다. 면접에서는 "밀도"라는 말로 정확히 말하세요.

항목	내용
해석	임령: 성숙림은 수관이 뽕뽕해 그늘·낮은 온도·수분 유지, 수피가 두껍고 수관 연료가 높아져 지표화에 강함. 어린 숲·단순림은 수관이 낮아 불이 위로 타오르기 쉽고 마른 낙엽이 많음. 임도: 진화 장비·인력이 빠르게 접근해 확산을 막음(발화원이 될 수 있다는 선행 연구도 있어 추가 연구 필요). 등산로: 담배꽂초·불법 취사 같은 부주의 발화
정책 시사	윤벌기(벌채 주기) 연장으로 숲을 더 오래 두기, 침엽수 조림지를 활엽수림으로 전환, 등산로 확장 제한과 입산 행동 규제, 임도는 핵심 진화 자산으로 인식
한계	1km 격자라 사면향·경사 같은 지형·미기후 미반영 / 임도·등산로 밀도는 대리변수(방문자 수·발화원 기록 없음) / 산림관리 자료(2015~2017)와 산불 자료(2022~2025)의 시간 차 / 강원·경북에 한정 / 임령 효과가 생태 요인 때문인지 지형적 고립(접근 제한) 때문인지 구분 못함
계절	산불의 68.8%가 1~4월에 발생, 4월이 가장 많음(20.4%)

A. 동기·배경 / Motivation & Background

A1. 자기소개와 지원동기 (1분)

Please introduce yourself and tell us why you applied.

한국어

안녕하세요. 저는 고등학교를 졸업하고 7년 정도 금융권이랑 마케팅 쪽에서 일하다가, 조금 늦은 나이에 대학에 들어갔습니다. 대학에서 생물학개론을 들었는데, 생명 현상이 너무 정교하고 신기해서 생명과학을 복수전공하게 됐어요. 그러다 자연과공생연구소에서 산불 발생 요인을 분석하는 논문에 2저자로 참여했는데, 그때 데이터를 분석하는 일이 정말 재미있다는 걸 알게 됐습니다. 그래서 이 역량으로 멸종위기종의 유전체 연구를 해보고 싶어서 지원했습니다. 특히 교수님 연구실이 VGP에도 참여하시고 다양한 종의 유전체를 분석해 오셔서, 제가 하고 싶은 연구랑 가장 잘 맞다고 생각했습니다.

English

Hello. After graduating from high school, I worked for about seven years in finance and marketing, and then I entered university at a later age. In an introductory biology class, I was fascinated by how precise and elegant living systems are, so I double-majored in life science. Later, I joined a wildfire analysis paper as a second author at the Nature and Symbiosis Research Institute, and that's when I realized how much I enjoy analyzing data. So I wanted to use these skills for genomic research on endangered species. Your lab takes part in the Vertebrate Genomes Project and has analyzed the genomes of many different species, so I felt it matches what I want to do very well.

A2. 왜 우리 연구실인가요?

Why our lab?

한국어

교수님 연구실은 VGP에 참여하시면서 다양한 종의 유전체를 분석해 오셨고, 아프리카 소의 유전 기원 연구랑 독도의 희귀 기생식물인 초종용의 유전체 분석도 하신 걸로 알고 있습니다. 저는 멸종위기종이나 희귀한 생물의 유전체를 직접 다루신 연구실이라는 점이 가장 끌렸어요. 제가 하고 싶은 게 멸종위기종의 유전체를 읽어서 유전적 다양성이랑 근친 정도를 보는 거라서, 이런 연구를 해 오신 곳에서 제대로 배우고 싶었습니다. 그리고 제가 서버에서 분석해 본 경험은 아직 없는데, 랩에서 실제 분석 흐름을 따라 하면서 그 부분을 채우고 싶습니다.

English

As I understand it, your lab takes part in the Vertebrate Genomes Project and has studied the origin of African cattle and the genome of *chojongyong*, a rare parasitic plant on Dokdo. What attracted me most is that your lab has worked directly on the genomes of endangered and rare organisms. I want to read the genomes of endangered species and examine genetic diversity and inbreeding, so I want to learn from a lab that has done this kind of work. I also haven't run analyses on a server yet, and I'd like to fill that gap by following the lab's real analysis workflow.

어떤 방향으로 바꾸고 싶으셨는지 알려 주시면 다시 맞춰 드리겠습니다. 이번에는 아직 읽지 않은 논문의 방법([])에 기대지 않도록 바꿨고, 랩의 연구 3가지 → 내 관심과의 연결 → 배우고 싶은 점 순서로 정리했습니다.

A3. 7년 일하다 갑자기 생명과학이요? 확신은 어디서 나왔나요?

Why change from business to life science?

한국어

막연하게 좋아서 온 건 아니고요, 직접 해보면서 확인했습니다. 복수전공으로 공부해 보고, 시민과학으로 산림곤충이나 수달 조사도 하고, 연구소랑 수목원에서 실제로 일도 해봤는데, 힘들어도 계속하고 싶다는 생각이 들었어요. 마케팅 때 KPI 짜고 데이터 보던 경험도 지금 데이터 해석할 때 꽤 도움이 됩니다.

English

It wasn't a vague dream. I tested it. I studied life science as a double major, joined citizen-science projects such as forest insect and otter surveys, and worked at a research institute and at the Korea National Arboretum. Even when it was hard, I felt I wanted to keep doing it. My marketing experience, such as setting KPIs and reading data, also helps me interpret data now.

A4. 왜 생태나 산림이 아니라 유전체인가요?

Why genomics rather than ecology or forestry?

한국어

저는 생명과학이라는 학문 자체를 좋아합니다. 수정이 시작되는 발생의 순간부터 생명체가 생명을 유지해 가는 과정까지, 알면 알수록 신비롭고 정교하더라고요. 어렵기도 하지만 그래서 더 재미있었습니다. 한편으로는 멸종위기종에 대한 특별한 마음이 있는데, 이런 미시적인 세계에 대한 관심이랑 멸종위기종에 대한 관심을 둘 다 연구할 수 있는 분야가 멸종위기종 유전체, 그러니까 보전유전체학이라고 생각했습니다. 그래서 오랫동안 열정을 가지고 깊이 파고들 수 있는 분야라고 느꼈습니다. 생태학적인 시각은 연구 결과를 현장이랑 연결할 때 계속 가져가겠습니다.

English

I love life science itself. From the moment of fertilization to how an organism keeps itself alive, it's amazing and elegant, and the more I learn, the more fascinating it gets, even though it is difficult. I also have a special feeling for endangered species. I realized the field that combines both interests, the microscopic world and endangered species, is conservation genomics. I thought it's a field where I can dig deep with passion for a long time. I'll keep an ecological perspective when I connect results to the field.

A5. 석사만 하실 건가요, 박사까지 하실 건가요?

Master's only, or a PhD too?

한국어

박사까지 진지하게 고려하고 있습니다. 석사 과정은 박사를 가기 전에 기초를 다지는 시간이라고 생각하고, 독립적인 연구자가 되려면 박사 과정이 필요하다고 봅니다. 그래서 석사에 입학하게 되면 먼저 역량을 충분히 길러서 박사 과정까지 이어 가고 싶습니다. 물론 석사 과정 자체에 최선을 다하겠습니다.

English

I'm seriously considering a PhD. I see the master's program as the time to build a foundation, and I think a PhD is necessary to become an independent researcher. So if I'm admitted, I want to build my skills first and then continue to a PhD. Of course, I'll do my best in the master's program itself.

참고: 지원서에는 "석사 후 취업(국립생태원·국립생물자원관)"도 쓰셨습니다. 면접에서는 박사 고려를 중심으로 말하되, "연구 기관에서 복원 연구를 하고 싶다"는 장기 목표는 같다고 이어 가면 일관됩니다.

B. 경험·역량 / Experience & Skills

B1. 산불 논문에서 정확히 뭘 하셨나요?

What exactly did you do in your wildfire paper?

한국어

2저자로 참여해서 연구 방법 구상, 데이터 수집이랑 전처리, 분석, 초고 작성, 시각화까지 맡았습니다. 이 논문은 강원도랑 경상북도에서 2022년부터 2025년 8월까지 난 산불을 대상으로, 임도, 등산로, 산림관리 같은 사람의 활동이 산불 발생에 어떤 영향을 주는지 본 연구였어요. 지역을 1km 격자로 나누고, 산불이 난 격자는 1, 안 난 격자는 0으로 두고 기상, 임상, 임도·등산로, 산림관리, 계절 변수를 설명변수로 썼습니다. 변수를 고를 때는 VIF로 다중공선성을 본 기준 모델이랑, Random Forest, XGBoost로 중요한 변수 상위 10개를 뽑은 모델, 세 가지를 비교했고, 성능이 가장 좋았던 Random Forest 변수로 최종 로지스틱 회귀분석을 했습니다. 그렇게 변수별 방향이랑 유의성을 해석했고, 최종 AUC는 약 0.80이었습니다. SHAP으로도 변수 기여를 시각화했습니다.

결과를 보면 유효습도가 높을수록 산불이 줄었고, 침엽수림 비율이 높을수록 늘었습니다. 임령이 높을수록 산불이 크게 줄었는데, 날씨를 빼면 산불을 억제하는 가장 중요한 요인이었어요. 사람 요인 중에서는 임도 밀도가 높을수록 산불이 줄었고, 반대로 등산로 밀도가 높을수록 위험이 늘어나는 경향이 있었습니다. 조림지 관리 같은 산림경영 변수는 통계적으로 유의하지 않아서 후속 연구가 필요하다고 정리했습니다. 가장 인상 깊었던 건 임령이 높을수록 산불이 억제된다는 결과였습니다.

English

I participated as the second author and was in charge of designing the approach, collecting and preprocessing data, analysis, writing the first draft, and visualization. The study looked at wildfires in Gangwon and Gyeongbuk provinces from 2022 to August 2025, and asked how human activities such as forest roads, hiking trails, and forest management affect wildfire occurrence. We divided the region into 1 km grid cells, coded cells with a wildfire as 1 and without as 0, and used weather, forest-stand, infrastructure, forest management, and seasonal variables as predictors. For variable selection, we compared three approaches: a baseline model that used VIF to handle multicollinearity, and models using the top 10 variables from Random Forest and from XGBoost. The Random Forest variable set performed best, so we used it in the final logistic regression to interpret the direction and significance of each effect. The final AUC was about 0.80. We also used SHAP to visualize each variable's contribution. The results showed that higher effective humidity reduced wildfires and a higher conifer ratio increased them. Older stand age strongly reduced wildfires; apart from weather, it was the most important suppressing factor. Among human factors, higher forest road density reduced wildfires, while higher hiking trail density tended to increase the risk. Forest management variables such as plantation tending were not statistically significant, so further research is needed. What impressed me most was that older stand age was associated with fewer wildfires.

△ 이전 버전과 달라진 점: 논문에서는 변수 선택을 "VIF 기준 모델 vs RF vs XGBoost" 세 방식으로 비교한 뒤 RF 변수 집합을 최종 모델에 썼고, 임도는 억제·등산로는 증가 경향입니다. 본인이 실제로 한 작업 순서와 다르면 알려 주세요.

B1-1. Random Forest가 뭔가요?

What is a Random Forest?

한국어

결정나무를 여러 개 만들어서 결과를 모아 판단하는 방법입니다. 나무마다 데이터와 변수를 조금씩 다르게 뽑아서 만들어서 한 나무가 틀려도 전체로는 안정적이예요. 이 연구에서는 Random Forest 기준으로 유효습도가 1위, 임령이 2위, 침엽수 비율이 3위였고, 상위 10개 변수를 최종 로지스틱 회귀에 썼습니다. 이 모델의 AUC가 0.8001로 XGBoost(0.7960)보다 조금 높았습니다.

English

It builds many decision trees and combines their results. Each tree uses slightly different data and variables, so even if one tree is wrong, the whole model stays stable. In our study, effective humidity ranked first, stand age second, and conifer ratio third, and we used the top 10 variables in the final logistic regression. Its AUC was 0.8001, slightly higher than XGBoost's 0.7960.

B1-2. XGBoost는 Random Forest랑 뭐가 다른가요?

How is XGBoost different from Random Forest?

한국어

Random Forest는 나무를 따로따로 만들어서 합치는 거고, XGBoost는 나무를 차례대로 만들면서 앞 나무가 틀린 부분을 다음 나무가 보완하는 방식입니다. 이 연구에서는 두 알고리즘이 고른 상위 10개 변수 중 9개가 겹쳐서 결과가 일관됐습니다.

English

Random Forest builds trees independently and combines them. XGBoost builds trees one after another, and each new tree corrects the errors of the previous ones. In our study, 9 of the top 10 variables overlapped between the two algorithms, so the results were consistent.

B1-3. VIF가 뭐고 왜 쓰셨나요?

What is VIF, and why did you use it?

한국어

VIF는 변수끼리 얼마나 겹치는지 보는 지표인데, 이 논문에서는 VIF가 10 미만인 변수를 후보로 썼습니다. VIF만으로 고른 기준 모델은 Pseudo R²가 0.1505, AUC가 0.7494였고, ML로 고른 변수를 쓴 최종 모델은 Pseudo R²가 0.1950이어서 설명력이 약 1.3배 높았습니다. 흥미로운 건 유효습도랑 임령이 VIF 진단에서는 공선성 때문에 빠졌는데 두 ML 알고리즘에서는 모두 최상위로 나왔다는 거예요. 그래서 ML이 산불의 실제 물리적 요인을 더 잘 잡아냈다고 해석했습니다.

English

VIF shows how much a variable overlaps with the others, and in this paper we kept variables with a VIF below 10 as candidates. The baseline model selected by VIF alone had a pseudo R-squared of 0.1505 and an AUC of 0.7494, while the final model using ML-selected variables had a pseudo R-squared of 0.1950, about 1.3 times higher explanatory power. Interestingly, effective humidity and stand age were excluded by the VIF check because of collinearity, but both ML algorithms ranked them at the very top. So we interpreted that ML captured the real physical drivers of wildfires better.

확인: 최종 모델에서 다중공선성을 어떻게 처리했는지(논문에서 어느 변수를 어떻게 정리했는지)는 본문만으로는 완전히 확인되지 않았으니 논문을 한 번 더 보세요.

B1-4. 머신러닝을 돌리고 왜 또 로지스틱 회귀를 하셨나요?

Why did you use logistic regression after machine learning?

한국어

이 연구의 핵심 목적이 예측 정확도 자체보다, 사람 활동 요인이 산불에 주는 방향이랑 유의성을 해석하는 거였기 때문입니다. Random Forest 같은 블랙박스 모델은 예측력은 좋지만 계수 수준의 해석이 어려워서, 산림청 산불위험예보 시스템을 개선하는 데 쓰기가 어렵거든요. 그래서 ML로 중요한 변수를 고른 다음, 로지스틱 회귀로 계수, 유의확률, 오즈비를 구해서 해석했습니다.

English

The main goal of this study was not prediction accuracy itself, but interpreting the direction and significance of the effects of human activities on wildfires. Black-box models like Random Forest predict well, but they lack coefficient-level transparency, which makes them hard to use for improving the Korea Forest Service's fire danger rating system. So after selecting important variables with ML, we used logistic regression to obtain coefficients, p-values, and odds ratios for interpretation.

B1-5. 임도나 등산로 결과가 서로 다르던데, 왜 그럴까요?

The results for forest roads and trails differed. Why?

한국어

제가 이해하기로는 임도가 있으면 산불이 났을 때 진화 차량이나 인력이 빠르게 접근해서 비교적 쉽게 진화할 수 있고, 그래서 산불이 확산되지 않기 때문입니다. 임도 밀도의 계수가 -2.72로 유의했어요(p=0.006). 반대로 등산로는 밀도가 높을수록 위험이 늘어나는 경향이 있었고, 오즈비가 약 4.3이었는데 10% 수준에서 유의했습니다. 담배꽂초나 불법 취사 같은 부주의가 원인일 수 있다고 봤습니다. 다만 인과관계라기보다 연관성이고, 임도는 접근성이 높아져서 오히려 발화원이 될 수 있다는 선행 연구도 있어서 추가 연구가 필요합니다.

English

As I understand it, when there is a forest road, firefighters and equipment can reach the site quickly and put the fire out sooner, so it doesn't spread. The coefficient for forest road density was -2.72 and significant ($p = 0.006$). On the other hand, higher hiking trail density tended to increase the risk, with an odds ratio of about 4.3, significant at the 10% level. We thought accidental ignitions, such as cigarette butts or illegal cooking, could be the cause. But this is an association rather than proof of causation, and some earlier studies suggest roads can become ignition sources by increasing access, so further research is needed.

△ 전 버전의 "임도·등산로 모두 가까울수록 억제"는 논문과 다릅니다. 거리 변수(임도·등산로까지의 거리)는 유의하지 않았고, 밀도 기준으로 임도는 억제, 등산로는 증가 경향입니다.

B1-6. 임령이 높을수록 산불이 억제된 이유는요?

Why did older stands have fewer wildfires?

한국어

논문에서는 성숙림은 수관이 뽕뽕해서 숲 바닥에 그늘이 지고 온도가 낮고 수분이 유지되는 효과가 있고, 나무가 오래 되면 수피가 두꺼워지고 수관 연료가 높이 올라가서 지표화에 더 강해진다고 해석했습니다. 반대로 어린 숲이나 단순한 조림지는 수관이 낮아서 불이 위로 타오르기 쉽고 마른 낙엽도 많아서 취약합니다. 한계로는 지형을 같이 보지 않아서, 이 효과가 생태적 요인 때문인지 지형적으로 접근이 어려워서인지 구분하지 못했다는 점이 있습니다.

English

In the paper, we explained that mature forests have dense canopies that shade the forest floor, lower temperatures, and retain moisture, and that as trees age their bark thickens and canopy fuels rise higher, making them more resistant to surface fires. In contrast, young forests and homogeneous plantations have low canopies that carry fire upward and a lot of dry fine debris, so they are more vulnerable. As a limitation, topography was not considered, so we could not tell whether this effect comes from ecological factors or from topographic isolation that limits human access.

B1-7. 데이터는 어떻게 구성했나요? 산불이 안 난 곳이 훨씬 많은데요?

How did you construct the dataset? Non-fire areas are far more numerous.

한국어

분석 단위는 1km×1km 격자입니다. 산림청에서 정보공개로 받은 산불 492건 중 주소 확인이 어렵거나 같은 격자에서 중복된 건을 빼고 산불 발생 격자 471개를 만들었어요. 산불이 안 난 격자는 훨씬 많아서 그냥 무작위로 뽑으면 지역 편향이 생기니까, 영동, 영서, 경북 지역별 발생 비율에 맞춰서 층화 무작위 추출로 1,000개를 뽑았습니다. 그래서 총 1,471개 격자이고, 머신러닝은 훈련 80%, 검증 20%로 나눴습니다.

English

The unit of analysis was a 1 km by 1 km grid cell. Of 492 wildfire records obtained from the Korea Forest Service through an information disclosure request, we excluded those with unclear addresses or duplicates in the same cell, leaving 471 wildfire grid cells. Non-fire cells are far more numerous, and simple random sampling would introduce regional bias, so we used region-based stratified random sampling to select 1,000 non-fire cells in proportion to the occurrence ratio in each region. That gave 1,471 cells in total, and for machine learning we split the data into 80% training and 20% validation.

B1-8. 어떤 변수를 썼고, 유효습도는 무엇인가요?

What variables did you use, and what is effective humidity?

한국어

변수는 다섯 그룹입니다. 기상(유효습도, 최대풍속, 강수량), 임상(평균 임령, 침엽수 비율, 흉고직경급, 임목밀도, 수고), 기반시설(임도 밀도, 등산로 밀도, 임도·등산로까지의 거리), 산림관리(조림지 관리, 천연림 관리, 기타), 계절입니다. 유효습도는 그날 습도만 보는 게 아니라 최근 며칠의 습도를 가중 평균해서, 최근일수록 가중치를 크게 준 값입니다. 숲의 연료가 누적해서 얼마나 말라 있는지를 나타냅니다. 산불이 난 격자는 발생 전날 기상을 썼습니다.

English

There were five groups of variables: weather (effective humidity, maximum wind speed, precipitation), forest stand (mean stand age, conifer ratio, diameter class, stand density, height), infrastructure (forest road density, trail density, distance to road and trail), forest management (plantation tending, natural forest tending, other), and season. Effective humidity is not just the humidity of one day; it is a weighted average of the last several days of humidity, with more weight on recent days, so it reflects how dry the forest fuel has become cumulatively. For wildfire cells, we used the weather of the day before the fire.

B1-9. 모델 성능은 어땠고 SHAP은 무엇인가요?

How well did the model perform, and what is SHAP?

한국어

최종 모델은 AUC 0.8001, McFadden Pseudo R^2 가 0.1950이었습니다. 강수량을 강수 유무로 바꿔서 다시 돌려도 AUC가 0.806으로 비슷해서 결과가 안정적이었어요. SHAP은 변수 값이 높을 때 산불 위험이 늘어나는지 줄어드는지를 점 하나하나로 보여주는 방법인데, 이 연구에서는 유효습도, 침엽수 비율, 임령이 가장 기여가 컸습니다. 로지스틱 회귀가 놓치기 쉬운 비선형 패턴을 보려고 같이 썼습니다.

English

The final model had an AUC of 0.8001 and a McFadden pseudo R-squared of 0.1950. When we replaced precipitation with a binary rain/no-rain variable, the AUC was 0.806, so the results were stable. SHAP shows, point by point, whether a high value of a variable increases or decreases wildfire risk; in our study, effective humidity, conifer ratio, and stand age contributed the most. We used it to see non-linear patterns that logistic regression can miss.

B1-10. 세운 가설은 무엇이고 결과는 어땠나요?

What were your hypotheses, and what were the results?

한국어

가설은 세 가지였습니다. H1, 임령과 수종 구성이 산불에 영향을 준다는 가설은 지지됐고, 임령이 높을수록 줄고 침엽수 비율이 높을수록 늘었어요. H2, 조림지 관리가 산불을 늘린다는 가설은 유의하지 않아서 기각했습니다. H3, 임도랑 등산로가 늘면 위험이 커진다는 가설은 부분적으로만 지지됐는데, 임도는 오히려 산불을 줄였고 등산로는 늘리는 경향이 있었습니다.

English

We had three hypotheses. H1, that stand age and species composition influence wildfires, was supported: older stands had fewer fires and higher conifer ratios had more. H2, that plantation tending increases wildfires, was rejected because it was not significant. H3, that more forest roads and trails increase risk, was only partially supported: roads actually reduced wildfires, while trails tended to increase them.

B1-11. 연구의 한계와 후속 연구, 정책 시사점은?

What are the limitations, follow-up research, and policy implications?

한국어

한계는 1km 격자라서 경사나 사면향 같은 지형과 미기후를 반영하지 못했고, 임도·등산로 밀도는 사람 활동의 대리변수라서 방문자 수나 발화원 기록이 있으면 더 좋다는 점입니다. 산림관리 자료는 2015~2017년이고 산불 자료는 2022~2025년이라 시간 차도 있고, 강원이랑 경북에 한정됩니다. 정책적으로는 윤벌기를 늘려서 숲이 더 오래 자라게 하고, 침엽수 조림지를 활엽수림으로 전환하는 것, 등산로 확장을 제한하고 입산 행동을 규제하는 것을 제안했습니다. 임도는 핵심 진화 자산이라고 봤어요.

English

As limitations, the 1 km grid could not reflect topography such as slope and aspect or microclimate, and road and trail density are proxies for human activity, so visitor counts or ignition records would be better. The forest management data were from 2015 to 2017 while the fire data were from 2022 to 2025, so there is a time gap, and the study was limited to Gangwon and Gyeongbuk. For policy, we suggested extending rotation ages so forests can grow older, converting conifer plantations to broadleaf forests, restricting the expansion of hiking trails and regulating hiker behavior. We saw forest roads as a core firefighting asset.

B2. 서버나 리눅스 경험은요?

Do you have experience with Linux or servers?

한국어

솔직하게 말씀드리면 리눅스나 서버에서 분석을 직접 돌려본 경험은 아직 없습니다. 대신 Python으로 머신러닝이랑 시각화는 해봤고 GIS로 공간 데이터도 다뤄봤습니다. 리눅스는 지금 독학으로 기본 개념을 공부하고 있고요. 입학하면 랩에서 쓰는 파이프라인을 따라 하면서 배우고, 처음 한두 달 안에 공개 데이터 한 개체를 처음부터 끝까지 돌려서 결과를 재현해 보는 게 목표입니다.

English

To be honest, I haven't run analyses on a Linux server yet. I have used Python for machine learning and visualization, and GIS for spatial data. I'm currently studying Linux on my own to learn the basics. If I'm admitted, I'll follow the lab's pipeline and learn from it, and my goal in the first one or two months is to run one public dataset from start to finish and reproduce the results.

솔직하게 말하는 게 가장 안전합니다. 시간이 되면 명령어 몇 개(ls, cd, grep, head, ssh)와 "서버에 접속해서 파일을 다루는 흐름"만 개념으로 알아 두세요.

B3. 활동이 많은데 연구에 집중할 수 있나요?

You have many activities. Can you focus on research?

한국어

제가 했던 활동들은 결국 전부 생물 보전에 대한 내용이었습시다. 생물다양성을 보전하고 싶은 마음이 활동으로 이어진 거라서, 연구랑 방향이 같습니다. 그리고 생물을 좋아하는 마음이 연구할 때 지치지 않게 해주는 동력이 될 거라고 생각해요. 연구하려면 체력도 중요하니까 가끔 숲이나 자연에 가서 같이 살아가는 생물들도 만나면서 재충전하고 체력도 관리하려고 합니다. 이런 것들이 연구에 방해가 되지 않도록 연구를 1순위로 두고 시간을 관리하겠습니다.

English

All of my activities were ultimately about biological conservation. They came from my wish to protect biodiversity, so they point in the same direction as my research. I also believe my love for living things will keep me from burning out. Stamina matters in research too, so I'll sometimes go to forests and nature to meet the living things we share the world with, and recharge. I'll put research first and manage my time so that these things never get in the way.

B4. 나이도 있고 연구 경력도 짧은데 따라갈 수 있겠어요?

You're older and have a short research career. Can you keep up?

한국어

나이가 있는 건 맞습니다. 그래도 배움은 죽을 때까지 계속 해야 하는 거라고 생각합니다. 남들보다 조금 늦게 시작했지만, 제가 뭘 좋아하고 뭘 잘하고 뭘가 부족한지를 객관적으로 알고 있고요. 부족한 부분은 보완하고, 여러 경험에서 얻은 노하우도 잘 활용해서 좋은 연구자가 되도록 노력하겠습니다.

English

Yes, I'm older, but I believe learning is something we continue for life. I started later than others, but I have an objective view of what I like, what I'm good at, and what I lack. I'll make up for what I lack, and use the know-how from my varied experiences to become a good researcher.

C. 연구계획 (가장 중요) / Research Plan

C1. 연구계획을 2분 정도로 설명해 주세요. 문제 → 기회 → 방법(지표 3개) → 새로움 → 한계 → 조율

Please describe your research plan in about two minutes.

한국어

제가 하고 싶은 연구는 산양의 유전체를 다시 분석해서 근친 정도랑 유전적 다양성을 보는 겁니다. 산양은 서식지 단절이나 폭설 때문에 개체수 감소가 걱정되는 멸종위기 I급 종인데요. 2018년에 선행 연구가 있었는데, 한 개체를 27배 심도로 읽어서 양 유전체에 맞춰 분석했습니다. 그런데 양은 산양이랑 약 천만 년 전에 갈라진 다른 종이라서, 참조랑 차이가 대략 2% 정도 되는 반면 이형접합도는 0.1% 정도거든요. 그래서 참조 차이가 결과에 영향을 줄 수 있습니다. 마침 2024년에 같은 속인 히말라야산양의 염색체 수준 참조유전체가 나와서, 같은 공개 데이터를 더 가까운 참조에 다시 맞춰볼 수 있게 됐습니다.

방법은 이 데이터를 새 참조에 매핑해서 변이를 찾은 다음에, 세 가지를 봅니다. 이형접합도로 유전적 다양성을, ROH, 그러니까 동형접합이 길게 이어진 구간으로 근친 정도를, PSMC로 과거 개체군 크기의 변화를 봅니다. 이때 양 참조랑 새 참조 결과를 같은 조건으로 비교해서, 참조를 바꾸면 결과가 얼마나 달라지는지도 확인하려고 해요. 다만 공개된 전장 데이터가 한 개체라서 개체군 전체에 대한 결론은 어렵다는 걸 알고 있고, 세부 계획이랑 개체를 늘리는 방법은 교수님과 상의해서 정하고 싶습니다. 결과는 복원이나 관리 정책의 기초 자료로 쓸 수 있다고 생각합니다.

English

I'd like to re-analyze the genome of the long-tailed goral, to evaluate its inbreeding and genetic diversity. The goral is an endangered species in Korea, and there is concern about population decline from habitat fragmentation and heavy snow. In 2018, a previous study sequenced one individual at 27x coverage and analyzed it by mapping to the sheep genome. But sheep split from the goral lineage about ten million years ago, so the sequence difference to the reference is roughly 2%, while heterozygosity is only about 0.1%. That means the reference can affect the results. In 2024, a chromosome-level reference genome of the Himalayan goral, in the same genus, was published, so now I can remap the same public data to a much closer reference.

For the method, I'll map the data to the new reference and call variants, and then look at three things.

Heterozygosity shows genetic diversity, ROH, or runs of homozygosity, shows the degree of inbreeding, and PSMC shows changes in past population size. I'll compare the results from the sheep reference and the new reference under the same conditions, to see how much the reference changes the results. I know the public whole-genome data is a single individual, so I can't draw population-level conclusions. I'd like to discuss the details and how to add more individuals with you. The results could provide baseline data for conservation and restoration policy.

C2. 이미 2018년에 분석된 데이터인데, 새롭게 알 수 있는 게 뭔가요?

That data was already analyzed in 2018. What's new?

한국어

새로운 건 데이터가 아니라 분석 방식입니다. 첫째, 같은 데이터를 같은 조건으로 두 참조에 맞춰서 이형접합도랑 PSMC가 달라지는지 비교해요. 그러면 선행 연구 결과가 참조 때문에 치우쳤는지 직접 확인할 수 있습니다. 둘째, 선행 연구에 없었던 ROH 분석을 염색체 위치랑 같이 봐서 근친 정도를 확인합니다. 그리고 선행 연구들이 PSMC를 돌릴 때 돌연변이율이랑 세대시간을 서로 다르게 써서 결과를 바로 비교하기 어려운데, 이것도 통일해서 비교할 수 있습니다.

English

What's new is the analysis, not the data. First, I'll run the same data under the same conditions against two references, and compare heterozygosity and PSMC. That lets me directly check whether the previous result was biased by the reference. Second, I'll add ROH analysis, which the previous study didn't do, with chromosome positions, to evaluate inbreeding. Also, previous studies used different mutation rates and generation times for PSMC, so their results can't be compared directly. I can standardize these and compare.

C3. 참조를 바꾸면 달라질 거라고 하셨는데, 어떻게 확인하고 뭐가 성공인가요?

How will you check the change, and what counts as success?

한국어

같은 데이터를 같은 조건으로 두 참조에 맞춰서 이형접합도 값이랑 PSMC 곡선을 비교하려고 합니다. 차이가 나면 선행 결과가 참조 영향을 받았다는 뜻이고, 차이가 없으면 기존 결과가 믿을 만하다는 확인이 되니까, 어느 쪽이든 의미가 있다고 생각합니다.

English

I'll map the same data to both references under the same conditions, and compare the heterozygosity values and the PSMC curves. If they differ, the earlier result was affected by the reference. If they don't, it confirms that the earlier result is reliable. I think either outcome is meaningful.

C4. 94%가 이미 양에 매핑되는데 왜 가까운 참조가 필요하죠?

94% of reads already mapped to sheep. Why do you need a closer reference?

한국어

매핑률 94%는 읽히긴 읽혔다는 거지 정확하게 읽혔다는 뜻은 아니거든요. 양이랑 차이가 대략 2%인데 이형접합도는 0.1% 정도라서, 작은 오정렬도 영향을 줄 수 있습니다. 실제로 얼마나 영향이 있는지는 두 참조를 비교해서 확인하겠습니다.

English

A 94% mapping rate means the reads were placed, but not necessarily placed correctly. The difference from sheep is about 2%, while heterozygosity is only about 0.1%, so even small misalignments can affect the estimate. I'll check how much it actually matters by comparing the two references.

C5. 개체가 하나뿐인데 뭘 결론 낼 수 있나요?

You only have one individual. What can you conclude?

한국어

맞습니다, 개체가 하나라서 개체군 수준 결론은 못 내립니다. 그래서 이 연구는 그 개체의 유전체 상태랑 방법 비교까지를 범위로 보고 있어요. 그리고 한국 산양은 북부랑 남부가 구분된다는 연구도 있어서, 한 개체가 전체를 대표하지 못한다는 점도 알고 있습니다. 보관 시료나 협력 기관으로 개체를 늘리는 건 교수님과 상의하고 싶고, 어려우면 수달 같은 다른 종으로 바꾸는 것도 생각하고 있습니다.

English

You're right. With one individual, I can't draw population-level conclusions. So the scope of this study is the genomic state of that individual and a comparison of methods. I also know that Korean gorals are divided into northern and southern populations, so one individual cannot represent the whole. I'd like to discuss with you how to add more individuals, for example through archived samples or collaborating institutions. If that's hard, I'm also thinking of applying the same approach to another species, such as the otter.

C6. 공개 데이터가 부족하면 어떻게 하시겠어요?

What if the public data is insufficient?

한국어

심도가 충분한 개체, 이 경우 27배 개체에만 PSMC를 적용하고요, 심도가 낮은 데이터는 낮은 심도에서도 쓸 수 있는 방법을 찾아보거나 집단 수준 분석에만 쓰려고 합니다. 데이터가 정말 부족하면 같은 방식을 수달 같은 다른 멸종위기 종에 적용하겠습니다.

English

I'll apply PSMC only to individuals with enough coverage, which here is the 27x individual. For low-coverage data, I'll look for methods that work at low coverage, or use it only for population-level analysis. If the data is truly insufficient, I'll apply the same framework to another endangered species such as the otter.

C7. 이형접합도가 낮으면 곧 위험한 건가요?

Does low heterozygosity always mean high extinction risk?

한국어

이형접합도가 낮다고 무조건 위험한 건 아니에요. 오랫동안 작은 집단이었던 종은 해로운 변이가 이미 걸러졌을 수도 있고, 반대로 최근에 급격히 줄어든 집단은 아직 이형접합도가 남아 있어도 앞으로 근친이 빨리 늘 수 있거든요. 그래서 ROH 길이랑 PSMC를 같이 봐야 한다고 생각하고, 한 개체의 이형접합도만으로 근친이라고 단정하지는 않겠습니다.

English

Not necessarily. A population that stayed small for a long time may have already purged harmful mutations. On the other hand, a population that declined recently may still have high heterozygosity but face rapidly increasing inbreeding. So I think ROH length and PSMC should be interpreted together, and I wouldn't conclude inbreeding from the heterozygosity of one individual alone.

C8. ROH가 뭐고 PSMC는 어떤 원리인가요?

What is ROH, and how does PSMC work?

한국어

ROH는 두 상동염색체가 같은 대립유전자로 쪽 이어지는 구간인데요, 시간이 지나면 재조합으로 잘게 쪼개지니까 긴 ROH는 최근 근친, 짧은 ROH는 오래된 조상을 뜻합니다. PSMC는 한 개체의 이형접합 위치 분포로 과거 개체군 크기를 추정하는 건데, 시간 축이 돌연변이율이랑 세대시간에 따라 달라지고, 최근 해상도가 낮다는 한계가 있습니다.

English

ROH is a long stretch where the two chromosomes carry identical alleles. Recombination breaks these stretches into shorter pieces over time, so long ROH suggests recent inbreeding and short ROH suggests more ancient ancestry. PSMC estimates past population size from the distribution of heterozygous sites in a single genome. Its limitations are that the time scale depends on the mutation rate and generation time, and that its resolution for recent time is low.

C9. 성염색체나 참조 품질은 어떻게 하실 건가요?

How will you handle sex chromosomes and reference quality?

한국어

참조 개체가 암컷이라 Y는 없고, X는 소나 무스콕이랑 비교해서 찾았다고 논문에 나와 있습니다. 저는 X를 빼고 상염색체만 계산할 생각입니다. 참조 품질은 스캐폴드 N50이 106 Mb 정도로 염색체 수준이고 BUSCO도 97% 가까이 되는데, contig N50이 3.7 Mb로 작은 편이라 contig 경계 근처는 조심해서 보겠습니다.

English

The reference individual is female, so there is no Y chromosome, and the paper identified the X by comparing it with cattle and muskox. I plan to exclude the X and use autosomes only. The reference is chromosome-level, with a scaffold N50 of about 106 Mb and BUSCO completeness of about 97%. But the contig N50 is only about 3.7 Mb, so I'll be careful near contig boundaries.

C10. 참조가 중국 개체인데, 한국 산양이랑 얼마나 달라요?

The reference is from China. How different is it from Korean gorals?

한국어

같은 속이지만 다른 종이라 차이는 있습니다. 그래도 양보다는 훨씬 가깝고요. 얼마나 차이 나는지는 매핑률이랑 두 참조 비교로 점검하겠습니다. 정확한 분기 시점은 제가 아직 확인하지 못했습니다.

English

They are different species in the same genus, so there is some difference. But they are much closer than sheep. I'll check this with mapping rates and by comparing the two references. I haven't confirmed the exact divergence time yet.

C11. 제가 다른 주제를 제안하면요?

What if I suggest a different topic?

한국어

제 계획은 초안이라서 교수님 의견이 우선이라고 생각합니다. 매핑하고 변이 찾고 집단유전학 지표 보는 흐름은 어떤 종을 해도 비슷해서, 다른 주제를 주셔도 열심히 배우겠습니다. 제 관심은 그 위에서 이어가겠습니다.

English

My plan is a draft, and your advice and the lab's direction come first. The workflow of mapping, variant calling, and population genetic metrics is shared across species, so I'll learn a lot from any topic you give me, and I can continue my own interests on top of that.

C12. 수달에도 관심 있으시던데 왜 산양인가요?

You also like otters. Why the goral instead?

한국어

둘 다 관심이 있습니다. 수달은 시민과학으로 현장에서 직접 접해 봤고요, 산양은 공개 데이터랑 가까운 참조가 있어서 새 시료 없이 시작할 수 있어서 먼저 골랐습니다. 수달도 같은 종 참조랑 동아시아 20개체 데이터가 공개돼 있어서, 한국 개체 자료를 구할 수 있으면 확장해 보고 싶습니다. 어느 쪽이 좋을지는 교수님과 상의하고 싶습니다.

English

I'm interested in both. I met otters directly through citizen-science activities. I chose the goral first because public data and a closer reference are available, so I can start without new samples. For the otter, a same-species reference and whole-genome data of East Asian individuals are public, so if I can get Korean samples, I'd like to extend the work. I'd like to discuss which direction is better with you.

C13. 결과가 정책에 어떻게 쓰이나요? 2년 안에 가능한가요?

How can the results be used for policy? Is it feasible in two years?

한국어

근친 정도랑 개체군 역사를 숫자로 보여주면, 서식지를 연결하거나 복원할 때 어떤 개체를 들여올지 논의하는 기초 자료가 됩니다. 월악산 복원 때 어느 집단 개체를 옮길지가 실제로 쟁점이었던 걸로 알고 있어요. 일정은 1학기에 수업이랑 파이프라인 익히기, 2학기에 데이터 처리랑 매핑, 3학기에 분석이랑 해석, 4학기에 논문 쓰기로 생각하고 있고, 범위가 크면 한 종, 적은 개체에 집중하겠습니다.

English

By showing inbreeding levels and population history with numbers, the results become baseline data for discussing habitat connectivity and which individuals to bring in for restoration. In the Worak Mountain restoration, which population to translocate from was an actual issue. For the schedule: in the first semester, coursework, learning the pipeline, and reviewing the literature. In the second, data processing and mapping. In the third, analysis and interpretation. In the fourth, thesis writing. If the scope is too big, I'll focus on one species and a small number of individuals.

E. 관심과목 질문 / Courses (Genetics · Genomics · Ecology)

E1. 유전학 수업에서 배운 내용과 연구와의 연결은?

What did you learn in your genetics course, and how does it connect to your research?

한국어

유전학은 멘델 유전부터 분자 수준의 유전자 발현과 조절까지, 유전 현상의 기본 원리를 배운 과목이었습니다. 특히 대립유전자 빈도가 세대를 거치면서 어떻게 변하는지, 근친교배가 개체군에 어떤 유전적 결과를 남기는지를 이 과목에서 접했습니다. 제가 석사 연구에서 다룰 이형접합도랑 동형접합 구간, 그러니까 ROH 같은 지표는 이 개념을 개체군 단위로 확장한 거라서, 여기서 다진 기초가 분석 결과를 해석하는 밑바탕이 될 거라고 생각합니다.

English

The genetics course covered the basic principles of heredity, from Mendelian inheritance to gene expression and regulation at the molecular level. In particular, I learned how allele frequencies change over generations, and what genetic consequences inbreeding leaves in a population. The indicators I will use in my master's research, heterozygosity and runs of homozygosity (ROH), extend these concepts to the population level, so I believe this foundation will help me interpret my results.

보충(복습): 근친이 있으면 이형접합 비율이 $2pq$ 에 $(1-F)$ 를 곱한 만큼 줄어듭니다. 지원서에는 없는 내용이니, 수업에서 배운 사례가 따로 있으면 그것을 우선하세요.

E2. 유전체학 수업에서 배운 내용과 연구와의 연결은?

What did you learn in your genomics course, and how does it connect to your research?

한국어

유전체학은 유전체를 대상으로 한 서열분석이랑 조립, 주석 작업의 흐름을 배운 과목이었습니다. 시퀀싱 데이터가 만들어지는 방식이랑 NCBI 같은 공개 데이터베이스를 활용하는 방법도 이 과목에서 익혔고요. 제 석사 연구는 공개된 재서열 데이터를 참조유전체에 매핑하고 변이를 호출하는 과정이 중심인데, 이 과목에서 배운 유전체 데이터 처리 흐름을 실제 분석에 적용할 계획입니다.

English

The genomics course covered the workflow of sequencing, assembly, and annotation of genomes. I also learned how sequencing data is generated and how to use public databases such as NCBI. My master's research centers on mapping public resequencing data to a reference genome and calling variants, and I plan to apply the genomic data-processing workflow I learned in this course to the actual analysis.

보충(복습): 조립은 읽은 조각을 contig → scaffold → 염색체 순으로 잇는 것(Hi-C 등), 주석은 유전자 위치와 기능을 표시하는 것입니다. 제 연구는 새로 조립하지 않고 기존 참조에 매핑하는 재서열 분석입니다. 지원서에 쓰지 않은 세부 내용이므로 수업에서 다뤘는지 확인하고 말하세요.

E3. 생태학 수업에서 배운 내용과 연구와의 연결은?

What did you learn in your ecology course, and how does it connect to your research?

한국어

생태학은 개체군과 군집, 생태계 수준에서 생물과 환경이 상호작용하는 방식을 다룬 과목이었습니다. 서식지 단편화가 개체군 크기에 미치는 영향이랑 생물다양성 평가 방법을 배웠고요. 유전체 분석으로 얻은 결과를 실제 보전 현장이랑 연결하려면, 이 과목에서 배운 생태학적 시각이 필요하다고 생각합니다.

English

The ecology course covered how organisms interact with their environment at the population, community, and ecosystem levels. I learned how habitat fragmentation affects population size and how biodiversity is assessed. To connect the results of genomic analysis to conservation in the field, I think the ecological perspective I learned in this course is essential.

보충(복습): 서식지가 쪼개지면 이동이 막혀 유전자 흐름이 줄고, 작은 집단에서는 유전자 부동과 근친으로 유전다양성이 감소합니다. 이 연결을 한 문장 더 붙이면 좋습니다.

D. 기타 / Other

D1. 요즘 이 분야 최신 이슈 중에 관심 있게 보신 게 있나요?

Which recent issues in your field have you followed?

한국어

솔직히 전부 따라가지는 못하는데요, 제가 이해하고 있는 건 두 가지입니다. 하나는 염색체 수준의 참조유전체가 계속 새로 나오고 있다는 거고, 이번 제 계획도 거기서 출발했습니다. 다른 하나는 보전유전체 쪽에서 이형접합도만 보지 않고 유전 부하나 유전적 구제까지 같이 보는 흐름입니다. 교수님 랩 논문은 초종용 논문을 봤고요, 아직 더 읽어 봐야 한다고 생각합니다. 입학하면 더 깊이 공부하겠습니다.

English

Honestly, I can't follow everything, but there are two things I understand. First, chromosome-level reference genomes keep being published, and my research plan started from that. Second, in conservation genomics, researchers don't look only at heterozygosity, but also at genetic load and genetic rescue. For your lab's papers, I've read the paper on the rare parasitic plant on Dokdo, and I think I need to read more. If I'm admitted, I'll study more deeply.

△ 말한 건 꼬리질문이 올 수 있으니 용어 정리 1부의 "유전 부하·유전적 구제·참조유전체 품질" 항목을 읽어 두세요. 초종용 논문은 "어떤 분석을 했는지" 한 문장은 말할 수 있게 확인하세요.

D2. 마지막으로 하고 싶은 말이나 질문 있으세요?

Do you have anything to add, or any questions?

한국어

입학 전에 미리 준비하면 좋은 게 있을까요? 그리고 공개 데이터를 기반으로 한 보전유전체 연구가 석사 주제로 가능한지도 궁금합니다. 오늘 시간 내주셔서 감사합니다.

English

Is there anything I should prepare before admission? I'm also wondering whether a conservation genomics project based on public data could work as a master's topic. Thank you for your time today.

모르는 질문이 나왔을 때 / When you don't know

모르는 질문이 나왔을 때 / When you don't know

- "정확히는 아직 확인하지 못했는데, 제가 이해한 바로는 ~입니다." — *"I haven't confirmed that yet, but my understanding is ~."*
- "그 부분은 제가 아직 부족해서, 입학하면 확인해서 배우겠습니다." — *"I'm still lacking in that area, and I'll study it if I'm admitted."*
- "교수님 의견을 듣고 계획을 조정하고 싶습니다." — *"I'd like to adjust my plan based on your advice."*

영어로 한 줄 설명 / Explain it in one sentence

Term	One-sentence explanation
Reference genome	A representative genome sequence that we align new reads to, like a map.
Resequencing	Sequencing an individual of a species that already has a reference genome and comparing it to that reference.
Sequencing depth (coverage)	The average number of times each position in the genome is read; 27x means each position is read about 27 times.
Variant calling	Finding positions where an individual's genome differs from the reference.
Heterozygosity	The proportion of positions where the two inherited alleles are different; it reflects genetic diversity.
Runs of homozygosity (ROH)	Long stretches where both chromosomes carry the same alleles; long ROH suggests recent inbreeding.
PSMC	A method that estimates past population size from the pattern of heterozygous sites in one genome.
Effective population size (N_e)	The size of an idealized population that would show the same amount of genetic drift as the real one.
Reference bias	When reads that differ a lot from the reference map poorly or incorrectly, so heterozygosity and variants are distorted.
Inbreeding depression	Reduced survival and reproduction because harmful recessive alleles become homozygous.
Genetic load	The burden that harmful mutations place on a population's fitness.
Genetic rescue	Bringing in individuals from another population to restore genetic diversity.
Habitat fragmentation	When habitat is broken into isolated patches, reducing movement and gene flow.
N50	A measure of assembly contiguity; half of the assembly is in pieces at least this long.
Random Forest	An ensemble of many decision trees built independently, whose results are combined.
XGBoost	A gradient boosting method that builds trees sequentially, each correcting the errors of the previous ones.
VIF	A measure of how much a variable is explained by the other variables; high values mean multicollinearity.
Logistic regression	A regression for yes/no outcomes that gives the direction and size of each variable's effect, such as odds ratios.
SHAP	A method that shows how much each variable pushes the prediction up or down for each observation.
Effective humidity	A weighted average of recent days' humidity, giving more weight to recent days, to reflect how dry the fuel is.
Stratified sampling	Random sampling that keeps the proportions of each region or group.
Odds ratio	How many times more likely an event is when a variable increases by one unit; above 1 means higher risk.

용어 정리 1부: 유전체학 (한글 · English · 설명)

먼저 비유로 잡기
· 참조유전체 (reference genome) = 정답 "지도". 새로 읽은 DNA 조각을 지도에 맞춰 붙여 차이를 찾는 게 재서열분석 (resequencing)
· 리드 (read) = 찢어진 책의 문장 조각 / 심도 (depth, 27x) = 같은 부분을 평균 27번 읽었다
· 변이 호출 (variant calling) = 지도와 다른 글자 찾기 / 이형접합도 (heterozygosity) = 엄마·아빠에게서 받은 글자가 서로 다른 자리의 비율
· ROH (runs of homozygosity) = 엄마·아빠 DNA가 똑같은 구간이 길게 이어진 곳 / PSMC = 한 개체의 DNA에 남은 조상의 "개체수 기록"을 거꾸로 읽는 방법

1) 기본 개념 (Basics)

한글	English	쉬운 설명
DNA / 유전자 / 유전체	DNA / gene / genome	4개 글자(A·T·G·C)로 쓴 정보 / 단백질을 만드는 정보 부분 / 한 생물의 DNA 전체(산양 약 2.6 Gb)
염색체	chromosome	DNA가 포장된 단위. 히말라야산양 참조는 28개 pseudochromosome
상염색체 / 성염색체	autosome / sex chromosome	쌍으로 존재 / X·Y. 수컷의 X는 하나라 이형접합도 왜곡 → 상염색체만 계산
대립유전자	allele	같은 자리(locus)의 서로 다른 글자. 부모에게서 하나씩
동형접합 / 이형접합	homozygous / heterozygous	두 글자가 같음 / 다름
SNP / 삽입·결실 / 변이	single nucleotide polymorphism / indel / variant	한 글자 차이 / 글자 삽입·삭제 / 참조와 다른 모든 자리
돌연변이율 / 세대시간	mutation rate (μ) / generation time (g)	PSMC에서 연도로 환산할 때 필수
중심원리	central dogma	DNA → RNA → 단백질
멘델 법칙	Mendel's laws	분리의 법칙 (segregation), 독립의 법칙 (independent assortment)

2) 시퀀싱·데이터·참조유전체 (Sequencing & reference)

한글	English	쉬운 설명
차세대 시퀀싱 / 숏리드 / 롱리드	next-generation sequencing (NGS) / short reads / long reads	Illumina(100~150bp)는 재서열에, PacBio·Nanopore는 참조 구축(조립)에 유리
재서열 / 새 조립	resequencing / de novo assembly	이미 참조가 있는 종을 비교(이번 계획) / 참조를 새로 만들(히말라야산양 논문)
심도	sequencing depth, coverage	각 위치를 평균 몇 번 읽었나. PSMC는 대략 18x 이상 권장, 27x 충분
FASTQ / BAM / VCF	FASTQ / BAM / VCF	읽은 원본(글자+품질) / 참조에 정렬한 결과 / 변이 목록
Phred 품질	Phred quality score (Q30)	글자 하나가 틀릴 확률. Q30 = 0.1%
조립 / contig / scaffold	assembly / contig / scaffold	조각을 이어 붙여 복원 / 끊김 없는 조각 / contig를 순서·방향으로 연결
N50	N50 (contig N50, scaffold N50)	연속성 지표. 이번 참조: contig N50 3.7 Mb, scaffold N50 106.66 Mb
완전성 평가	BUSCO (Benchmarking Universal Single-Copy Orthologs)	보존 유전자가 온전히 있는 비율 (이번 참조 96.9%)

Hi-C / 염색체 수준	Hi-C scaffolding / chromosome-level assembly	염색체 안 접촉 정보로 scaffold를 염색체 단위로 정렬
주석	annotation (gene prediction, functional annotation)	유전자 위치 예측과 기능 부여
척추동물 유전체 프로젝트	Vertebrate Genomes Project (VGP)	모든 척추동물의 고품질 참조 구축 국제 프로젝트
SRA / BioProject / BioSample	Sequence Read Archive / BioProject / BioSample	NCBI 공개 시퀀싱 저장소 / 연구 번호(PRJNA...) / 시료 번호(SAMN...)

3) 이번 연구의 분석 단계 (Analysis steps)

한글	English / 도구	하는 일 · 면접용 한 문장
품질관리	quality control · fastp	어댑터·저품질 염기 제거. "오류 많은 구간을 걸러내는 단계입니다."
매핑	read mapping · BWA-MEM	리드를 참조에 정렬. "지도에 조각을 맞춰 붙이는 단계입니다."
정렬·중복 제거	sorting, duplicate removal · samtools	PCR로 복제된 중복 리드 제거
변이 호출·필터링	variant calling, filtering · bcftools	유전자형 판정 → VCF. QUAL·심도(DP)·매핑품질(MQ)로 걸러냄
이형접합도	heterozygosity	(이형접합 SNP 수) ÷ (판정 가능한 상염색체 글자 수). 선행 연구 0.00113 (약 0.1%)
동형접합 구간	runs of homozygosity (ROH) · bcftools roh, PLINK	$F_{ROH} = ROH \text{ 총 길이} \div \text{상염색체 길이}$
개체군 역사	demographic history · PSMC	한 개체의 이형접합 분포로 시점별 N_e 추정

4) 집단유전학 (Population genetics)

한글	English	쉬운 설명
하디-바인베르크 평형	Hardy-Weinberg equilibrium (HWE)	무작위 교배·큰 집단·선택 없음이면 유전자형 비율이 $p^2 : 2pq : q^2$ 로 유지. 깨진 정도로 근친·구조 추정
유전자 부동	genetic drift	작은 집단에서 대립유전자 빈도가 우연히 변함 → 다양성 감소
유효 개체군 크기	effective population size (N_e)	유전적으로 현재 집단과 같은 부동을 보이는 이상 집단의 크기. 실제 개체수 보다 보통 작음
병목 / 창시자 효과	bottleneck / founder effect	집단이 급감하거나 소수에서 시작해 다양성이 크게 줄어듦
이형접합도 / 뉴클레오티드 다양성	observed & expected heterozygosity (H_o/H_e) / nucleotide diversity (π)	실제·기대 이형접합 비율 / 두 서열의 평균 차이
근친계수	inbreeding coefficient (F , F_{ROH})	두 대립유전자가 같은 조상에서 온 확률. ROH로 추정
ROH 길이	ROH length	재조합으로 쪼개짐 → 긴 ROH = 최근 근친, 짧은 ROH = 오래된 조상
재조합 / 연관	recombination / linkage	상동염색체가 DNA를 교환 / 가까운 변이가 함께 유전
PSMC	pairwise sequentially Markovian coalescent	한계: 고심도 필요, 최근 해상도 낮음, $\mu \cdot g$ 가정에 비례, 집단 구조가 N_e 변화로 보일 수 있음
합착(공조상) 이론	coalescent theory	두 서열이 공통 조상에서 만나는 시점으로 개체군 역사를 추정하는 이론
집단 분화 / 분산 분석	fixation index (F_{st}) / AMOVA	집단 간 분화 정도(0~1) / 변이를 집단 간·집단 내로 분해. 전수원 논문 F_{st} 0.282

하플로타입 / mtDNA control region	haplotype / mitochondrial DNA control region	한 DNA 조각의 서열 유형 / 모계 유전 DNA의 변이가 큰 부위(근친·유전 부하는 못 봄)
------------------------------	--	--

5) 보전유전학 (Conservation genetics)

한글	English	쉬운 설명
근친 약세	inbreeding depression	동형접합이 늘어 해로운 열성 변이가 발현 → 생존·번식 저하
유전 부하	genetic load (masked / realized)	해로운 변이의 부담. 숨은 부하(이형접합) vs 발현되는 부하(동형접합)
퍼징	purging	근친이 오래 지속되며 강한 유해 변이가 제거됨 → 다양성이 낮다고 무조건 위험하지는 않음
유전적 구제	genetic rescue	다른 집단 개체를 들여 다양성 회복
이계교배 약세	outbreeding depression	지나치게 다른 집단과 교배해 적합도 저하
서식지 단편화	habitat fragmentation	서식지가 쪼개져 이동·유전자 흐름 차단
유전자 흐름	gene flow	집단 간 대립유전자 이동
관리 단위	management unit (MU)	유전적으로 구분되어 따로 관리할 집단(전수원 논문: 북부/남부)
참조 편향	reference bias	참조와 차이가 큰 리드는 매핑 안 되거나 오정렬 → 이형접합도·변이 왜곡. 산양: 양과 약 2%, 이형접합 약 0.1%
최소존속개체군	minimum viable population (MVP)	일정 기간 멸종하지 않고 유지되는 최소 개체군 크기

용어 정리 2부: 산불 논문 통계·머신러닝 (한글 · English)

논문 흐름: ① 1km 격자·변수 만들기 → ② VIF 기준 모델 / RF / XGBoost 세 방식으로 변수 선택 → ③ 성능이 가장 좋은 RF 상위 10개 변수로 로지스틱 회귀 → ④ 계수·오즈비·p값, SHAP으로 해석 → ⑤ 가설 검증과 정책

한글	English	쉬운 설명	이 논문에서는
결정나무	decision tree	"임령이 30년 이상인가? 예/아니오"처럼 질문을 이어 가며 데이터를 나누는 스무고개 모델	RF·XGBoost의 기본 단위
랜덤 포레스트	Random Forest	결정나무를 수백 개 만들되 나무마다 데이터·변수를 다르게 뽑고 결과를 모아 판단. 안정적이고 과적합에 비교적 강함. 변수 중요도를 줌	AUC 0.8001, 상위 10개 변수를 최종 모델에 사용
XGBoost	gradient boosting (XGBoost)	나무를 순서대로 만들며 앞 나무의 오차를 다음 나무가 보완. 성능이 좋지만 설정값에 민감	AUC 0.7960, 상위 10개 중 9개가 RF와 겹침
변수 중요도	feature importance	그 변수가 예측에 얼마나 도움이 되나. 한계: 방향을 모름, 상관 변수끼리 중요도가 나뉨	1위 유효습도, 2위 임령, 3위 침엽수 비율(RF)
다중공선성	multicollinearity	설명변수끼리 너무 닮은 상태 → 회귀 계수 불안정	VIF로 점검
분산팽창계수	variance inflation factor (VIF)	$VIF = 1/(1-R^2)$. 이 논문은 10 미만이면 후보로 사용	VIF 기준 모델: AUC 0.7494, Pseudo R^2 0.1505
로지스틱 회귀	logistic regression	"예/아니오"(산불 발생 여부) 결과의 확률을 설명. 계수의 부호 = 방향, $\exp(\text{계수})$ = 오즈비	최종 모델. 목적은 예측보다 해석
오즈비	odds ratio (OR)	변수가 1단위 늘 때 사건이 몇 배 더 일어나기 쉬운가 (1보다 크면 증가, 작으면 감소)	침엽수 4.24, 임령 0.057, 등산로 4.32

유의성 (p값)	statistical significance (p-value)	우연히 이런 결과가 나올 가능성. 유의하지 않음 = 이 데이터로 확신 못함	조림지 관리 p=0.954 (유의 X)
설명력 지표	McFadden pseudo R ²	로지스틱 회귀의 적합도(0~1). 0.2~0.4면 좋은 편으로 보기도 함	최종 0.1950, VIF 기준 0.1505
AUC	area under the ROC curve	발생·미발생을 구분하는 능력 (1에 가까울수록 좋음, 0.5는 찍기 수준)	최종 0.8001
SHAP	SHapley Additive exPlanations	각 격자(점)에서 변수 값이 위험을 올리는지 내리는지 보여주는 설명 기법. 빨강 = 변수 값 높음	유효습도·침엽수·임령 기여도
층화 무작위 추출	stratified random sampling	지역별 비율을 유지하며 무작위로 뽑는 방법	비발생 격자 1,000개 (경북 566, 영서 296, 영동 138)
클래스 불균형	class imbalance	한쪽 결과(비발생)가 훨씬 많은 상태	발생 471 : 비발생 1,000
격자	grid cell (1 km × 1 km)	지역을 바둑판처럼 나눈 분석 단위	QGIS로 구축
유효습도	effective humidity	최근 며칠의 습도를 최근일수록 크게 가중 평균한 값(연료의 누적 건조도)	감쇠계수 0.7
훈련·검증 분할	train / validation split (80/20)	일부로 학습하고 나머지로 성능 검증	머신러닝 단계 (층화)
강건성 검사	robustness check	가정을 바꿔도 결과가 유지되는지 확인	강수량을 유무(이진)로 바꿔도 AUC 0.806
과적합 / 교차검증	overfitting / cross-validation	훈련 데이터에만 잘 맞춤 / 나눠 번갈아 검증	이 논문은 80/20 분할로 검증
상관과 인과	correlation vs causation	"밀도가 높을수록 억제"는 연관성이지만 원인 단정이 아님	임도·등산로 설명에 붙이기
임령 / 임도 / 숲아베기 / 윤벌기	stand age / forest road / thinning / rotation age	산불 논문 용어	