

대학원 면접 대비 자료 (서울대 농생명공학부 바이오모듈레이션 전공 · 생물정보 및 집단유전학)

이 문서는 제출하신 자기소개 및 수학(연구)계획서를 기준으로 작성했습니다. 모범 답안은 뼈대 예시입니다. 실제로 하지 않은 경험을 말하지 않도록, [] 안은 본인 사실로 바꿔 넣으세요. 면접관은 대개 지원서에 쓴 문장을 그대로 짚습니다. 지원서의 모든 단어(fastp, BWA-MEM, ROH, PSMC 등)에 대해 "이게 뭐고 왜 쓰나"를 한 문장으로 답할 수 있으면 절반은 성공입니다.

0. 먼저 알아둘 것 — 면접관 입장에서 보는 지원서

강점으로 읽히는 부분 - 7년 실무 + 늦은 진학 → 동기가 분명하고 성실해 보임 - 논문 2저자, 데이터 분석 (RF/XGBoost) 경험, 글쓰기·전달력 - 연구계획이 구체적임 (종, 도구, 순서까지 명시) — 계획서 중 상위권에 속함 - 약점(서버 경험 부족)을 스스로 인정하고 보완책을 제시함

면접관이 파고들 가능성이 큰 부분 (= 대비 1순위) 1. 연구계획의 참신성: "공개 데이터를 새 참조유전체에 다시 맞추다"가 석사 논문이 될 만큼 새로운가? 이미 같은 데이터로 het/ROH/PSMC를 한 논문이 있지 않은가? 2. 데이터 충분성: 산양 공개 재서열 데이터가 실제로 몇 개체, 몇 배(x) 심도인가? PSMC는 고심도 단일 개체가 필요하다. 3. 기술적 정합성: 이형접합도·ROH·PSMC의 원리와 한계, 참조유전체 편향(reference bias) 4. 전공 연결성: 산불·GIS·마케팅 경력 이 왜 유전체 연구로 이어지는가 5. 계획의 숙지도: 본인이 쓴 계획을 얼마나 이해하는가 (← 가장 걱정하신 부분) 6. 현실 조건: 기간제 근무 종료(12/31) 후 입학 시점, 박사 vs 취업 모호함

⚠ 면접 전에 반드시 직접 확인할 사실 (제가 검증할 수 없는 부분) - [] 히말라야산양(*N. goral*) 염색체 수준 참조유전체(2024)의 정확한 출처·어셈블리 accession·품질(N50, BUSCO) - [] NCBI SRA에 있는 산양(*N. caudatus*) 재서열 데이터의 BioProject, 개체 수, 시료 출처(국내 어느 개체군/동물원 개체?), 심도(x), 원 논문 - [] 그 원 논문이 이미 무엇을 분석했는지 (어떤 참조에 맞췄고, het/ROH/PSMC를 했는지) → 내 연구의 차별점이 여기서 결정됩니다 - [] *N. caudatus*와 *N. goral*의 분류학적 관계(별종인지, 분화 시점), 한국 산양의 학명/아종 표기 - [] 산양 *N. caudatus* 자체의 참조유전체가 이미 존재하는지 (있다면 계획의 전제가 약해지므로 반드시 알고 가야 함) - [] 김희발 교수님 연구실의 최근 논문 3~5편 초록 (특히 아프리카 소 논문에서 실제로 쓴 분석: PCA, ADMIXTURE, 계통수, 국소 조상성 추정 등. 지원서에 "유사하다"고 썼으므로 어느 부분이 유사한지 설명할 수 있어야 함)

이 확인이 안 되면 답변에서 "확인한 바로는"이라고 말할 수 없습니다. 모르는 부분은 "확인 중이며, 입학 후 지도교수님과 확정하겠다"라고 솔직히 말하는 편이 지원서 문구("공개 데이터의 개체 수와 심도를 확인한 뒤 지도교수님과 논의하여 확정")와도 일관됩니다.

1. 예상 질문과 모범 답안 예시

A. 동기·배경

Q1. 간단히 자기소개와 지원 동기를 말씀해 주세요. (1~2분)

저는 고등학교 졸업 후 집안 사정으로 먼저 사회생활을 시작해 금융·카드·스타트업 마케팅에서 7년을 근무했습니다. 스타트업에서 자기 일에 진심인 사람들을 만나며 저도 열정을 쏟을 수 있는 일을 찾고 싶어 대학에 진학했고, 생물학개론을 들으며 생명과학을 복수전공하게 되었습니다. 이후 자연과공생연구소에서 산불 발생요인 분석 연구에 참여해 데이터 분석의 즐거움을 알게 되었고, 이 역량을 멸종위기종의 유전체 연구에 쓰고 싶다는 생각으로 지원했습니다. 특히 교수님 연구실이 VGP에 참여하며 다양한 분류군에서 유전체 조립과 집단유전학 분석을 해 오신 점이 제 관심과 가장 잘 맞았습니다.

팁: 외워서 읊기보다 "7년 → 전환점 → 데이터 분석 → 유전체"의 4박자만 기억하세요. 1분을 넘기지 않기.

Q2. 마케팅·금융 7년 경력이 있는데, 왜 완전히 다른 분야로 가려 하나요? 확신의 근거는?

막연한 동경이 아니라 시험을 해 본 결과입니다. 대학 때 복수전공으로 생명과학을 공부했고, 시민과학 활동(산림 곤충·야생벌 모니터링, 수달 조사)과 이화여대 행동생태연구실, 자연과공생연구소, 국립수목원까지 연구 현장에서 일해 보며 "이 일이 힘들어도 계속하고 싶다"는 것을 확인했습니다. 또 마케팅에서 KPI 설계와 데이터 기반 캠페인 실행을 했던 경험은 데이터를 해석하고 결과를 전달하는 데 직접 도움이 됩니다.

Q3. 야생동물 보전에 관심이 있는데 왜 생태학·산림학이 아니라 유전체/생물정보인가요?

현장 조사만으로는 개체군이 얼마나 위태로운지 정량화하기 어려운 경우가 많습니다. 산불 연구에서 데이터를 분석해 보니 "관찰"을 "근거"로 바꾸는 일이 흥미로웠습니다. 유전체는 개체수를 세는 것으로는 보이지 않는 근친 정도, 과거 병목, 유전적 다양성을 정량적으로 보여 주기 때문에 보전정책의 객관적 근거가 됩니다. 생태학은 연구 결과를 현장과 연결하는 시각으로 계속 가져가려 합니다.

Q4. 왜 우리 연구실인가요? 교수님 연구 중 아는 것은?

교수님 연구실은 VGP 참여 연구실로 다양한 분류군의 유전체 조립과 집단유전학 분석을 수행하셨고, 아프리카 토착 소 품종의 기원 연구에서는 [논문에서 사용한 방법을 구체적으로: 예: 집단 구조 분석·집단 간 유전적 혼합 추정 등]을 활용하신 것으로 이해하고 있습니다. 제가 하려는 재서열 데이터 기반 집단유전학 분석과 [공통된 단계: 매핑→변이 호출→집단유전학 분석]이 겹쳐 랩의 분석 환경과 노하우를 빠르게 배울 수 있다고 생각했습니다.

⚠ []를 논문을 읽고 채워야 합니다. 안 읽고 가면 이 질문이 가장 위험합니다.

Q5. 석사만 할 건가요, 박사까지 갈 건가요? 졸업 후 계획이 모호한데요.

지금은 석사 과정에서 충분히 훈련을 받고 그 경험을 바탕으로 결정하려 합니다. 다만 장기 목표가 멸종위기종 복원 연구자라서, 연구에 대한 적성이 확인되고 연구 주제가 더 확장될 여지가 있다면 박사 진학을 진지하게 고려하고 있습니다. 취업을 한다면 국립생태원·국립생물자원관 같은 곳에서 복원 연구를 하는 것이 목표입니다.

팁: 면접관은 "중도 이탈 안 하고 끝까지 할 사람인가"를 봅니다. "열린 마음"만 반복하지 말고, "석사 과정은 확실히 끝까지 한다"를 분명히 말하세요.

Q6. 지금 국립수목원 기간제인데 입학 일정에는 문제가 없나요?

계약이 2026년 12월 31일까지라 입학 시기와 겹치지 않습니다. 남은 기간에는 [리눅스·R/Python 학습, 랩 논문 읽기]를 계속하겠습니다.

(입학 학기가 언제인지 모집요강으로 정확히 맞춰 보세요.)

B. 학업·연구 경험

Q7. 산불 논문에서 본인이 정확히 한 일은? 어떤 방법을 썼고 결과는?

2저자로 연구 방법 구상, 데이터 수집·전처리, 분석, 초고 작성, 시각화를 맡았습니다. 산불 발생 여부를 종속변수로 하고 임도·등산로·산림관리 같은 인위적 요인을 설명변수로 하여 Random Forest, XGBoost를 적용했고, [변수 중요도에서 무엇이 상위였는지·모델 성능 지표(AUC 등)·교차검증 방식]를 확인했습니다. 결과적으로 [핵심 결론 한 줄].

준비물: 논문을 다시 읽고 ① 표본 단위 ② 변수 목록 ③ 불균형 데이터 처리 ④ 검증 방법 ⑤ 결론 5가지를 말할 수 있게 하세요. "Random Forest란 무엇인가", "과적합 방지법", "변수 중요도 해석의 한계(상관된 변수)"가 후속 질문으로 자주 나옵니다.

Q8. 산불 분석이 유전체 연구와 어떻게 연결되나요?

도메인은 다르지만 "대량의 데이터를 정리하고 품질을 검증한 뒤 통계로 해석하고 시각화한다"는 흐름이 같습니다. 유전체 분석에서도 품질관리, 필터링, 통계적 해석, 결과 전달이 핵심이라 이 경험이 바탕이 됩니다. 아직 유전체 데이터를 직접 다뤄 본 경험은 부족하다는 점은 인정하고, 그 부분은 [독학 내용]으로 채우고 있습니다.

Q9. 유전학/유전체학 수업에서 가장 기억에 남는 개념은?

(본인의 진짜 기억 하나를 고르세요. 예시) 하디-바인베르크 평형이 깨지는 조건과 유전자 부동입니다. 작은 개체군에서 대립유전자 빈도가 우연히 변하고 동형접합이 늘어나는 것이 근친교배와 어떻게 이어지는지 배웠는데, 이것이 제 연구계획의 이형접합도·ROH 분석의 이론적 바탕입니다.

Q10. 프로그래밍·리눅스·R/Python 수준은?

Python으로 머신러닝 모델링과 시각화를, GIS로 공간 데이터 처리를 해 봤습니다. 리눅스 커맨드라인과 서버 기반 파이프라인은 현재 독학 중이며 [구체 수준: 기본 명령어(cd, ls, grep, awk), 간단한 쉘 스크립트, conda 환경, 샘플 데이터로 fastp→BWA→samtools 실행 등]까지 해 봤습니다.

⚠ **면접 전까지 최소한 작은 데이터(예: 박테리아 또는 단일 염색체 일부)로 fastp → BWA-MEM → bcftools 전 과정을 직접 한 번 돌려 보세요. 한 번이라도 해 봤다는 사실이 답변의 설득력을 크게 바꿉니다. (6장 학습 플랜 참조)**

Q11. 단점으로 서버 경험 부족을 쓰셨는데, 입학 후 초기에 어떻게 극복하실 건가요?

입학 전에는 리눅스 기초와 파이프라인 구조를 익히고, 입학 후에는 랩의 기존 파이프라인과 선배들의 방식을 먼저 따라 하며 배우겠습니다. 처음 1~2개월 안에 공개 데이터 한 개체를 처음부터 끝까지 돌려서 결과를 재현해 보는 것이 목표입니다.

C. 연구계획 (핵심)

Q12. 연구계획을 2분 안에 설명해 주세요.

국내 멸종위기종 산양의 유전적 상태를 평가하고 싶습니다. 산양은 서식지 단절로 개체군이 고립되어 유전다양성 감소가 우려되는데, 유전체 수준 연구는 충분하지 않습니다. 선행 연구로 NCBI에 공개된 재서열 데이터가 있지만 가까운 참조유전체가 없어 먼 종에 맞춰 분석할 수밖에 없었습니다. 그런데 2024년 같은 속인 히말라야산 양의 염색체 수준 참조유전체가 나와, 같은 데이터를 계통적으로 훨씬 가까운 참조에 다시 맞출 수 있게 되었습니다. 방법은 ① 공개 데이터를 내려받아 ② fastp로 품질관리하고 ③ BWA-MEM으로 새 참조에 매핑한 뒤 ④ bcftools로 변이를 호출하고 ⑤ 이형접합도와 ROH로 근친 정도를 평가하고 ⑥ PSMC로 과거 개체군 크기 변화를 추정합니다. 새로운 채집이나 시퀀싱 없이 가능하다는 점이 장점이고, 결과는 복원·관리 정책의 기초 자료가 될 수 있습니다.

이 답변은 거의 외울 정도로 연습하세요. 모든 후속 질문의 출발점입니다.

Q13. 왜 산양인가요? 다른 멸종위기종도 많은데.

세 가지입니다. 첫째, 멸종위기 I급이자 천연기념물로 서식지 단절에 의한 고립이 뚜렷해 근친·유전다양성 감소 문제가 현실적입니다. 둘째, 공개 재서열 데이터가 있어 새 시료 없이 연구가 가능합니다. 셋째, 가까운 속의 염색체 수준 참조유전체가 새로 생겨 재분석의 가치가 큼니다. 데이터가 부족한 것으로 확인되면 같은 틀로 다른 멸종위기종으로 대상을 바꿀 수도 있습니다.

Q14. 이미 공개된 데이터를 다시 분석하는 건데, 새로움(novelty)이 있나요?

새로움은 데이터가 아니라 분석 해상도에 있다고 생각합니다. 먼 종 참조에 맞췄을 때는 분기가 큰 영역에서 리드가 잘 맞지 않아 이형접합도가 낮게 추정되거나 ROH 경계가 부정확해질 수 있습니다. 가까운 염색체 수준 참조에서는 염색체 위치 정보가 있어 ROH를 위치·길이별로 평가할 수 있습니다. 또한 [선행 연구에서 하지 않은 분석: 예: ROH 길이 분류를 통한 최근 vs 오래된 근친 구분, 유전 부하(deleterious variants) 추정, 개체군 구조]를 추가해 확장하려 합니다. 정확한 차별점은 선행 연구를 더 정리한 뒤 지도교수님과 논의해 확정하겠습니다.

⚠ 이 질문에 대한 최선의 답은 "원 논문이 무엇을 했고 내가 무엇을 더하는지"를 구체적으로 말하는 것입니다. 위 []를 반드시 채우세요.

Q15. 참조유전체가 가까우면 왜 좋은가요? (reference bias)

리드를 참조에 정렬할 때 참조와 차이가 많은 리드는 매핑되지 않거나 낮은 품질로 처리됩니다. 참조가 먼 종이면 차이가 많은 영역이 누락되고, 반대로 서열이 잘못 정렬되어 가짜 변이가 생길 수도 있습니다. 결과적으로 이형접합도·변이 수가 편향되고 ROH 추정이 부정확해집니다. 같은 속의 참조는 서열 차이가 적어 매핑률과 변이 호출 정확도가 올라갑니다. 다만 *N. gora*와 *N. caudatus*도 별개 종이므로 편향이 완전히 사라지는 것은 아니라는 점은 인지하고 있습니다. 이를 [매핑률, 커버리지 분포, 가능하면 다른 참조와의 비교]로 점검하겠습니다.

Q16. 공개 데이터가 개체 수가 적거나 심도가 낮으면 어떻게 하나요?

먼저 개체 수와 심도(x)를 확인해 분석 범위를 정합니다. PSMC는 단일 개체의 고심도(대략 $\geq 18x$ 권장) 데이터가 필요하므로, 조건이 되는 개체에만 적용합니다. 심도가 낮으면 변이 호출 불확실성이 커서 이형접합도가 과소추정될 수 있으므로, 낮은 심도에서도 쓸 수 있는 접근(유전자형 가능성 기반 방법, 예: ANGSD)을 검토하거나, 심도가 낮은 개체는 집단 수준 분석에서만 활용하겠습니다. 데이터가 정말 부족하면 대상 종을 조정합니다.

Q17. 이형접합도가 낮다는 것이 곧 멸종 위험이 높다는 뜻인가요?

반드시 그렇지는 않습니다. 이형접합도가 낮아도 오랜 시간 작은 개체군을 유지하며 해로운 변이가 이미 제거(purging)된 종은 근친 약세가 덜할 수 있습니다. 반대로 최근 급격히 줄어든 집단은 이형접합도는 남아 있어도 앞으로 동형접합이 빠르게 늘어날 수 있습니다. 그래서 이형접합도 하나가 아니라 ROH 길이 분포(최근/오래된 근친 구분), PSMC로 본 역사, 가능하면 유전 부하를 함께 해석해야 한다고 생각합니다. 또 개체 수가 적으면 추정에 불확실성이 크다는 점도 한계로 명시하겠습니다.

Q18. ROH가 무엇이고 어떻게 구하나요? 길이는 무엇을 뜻하죠?

ROH(Runs of Homozygosity)는 한 개체의 염색체에서 양쪽 상동염색체가 같은 대립유전자로 이어지는 연속 구간입니다. 부모 양쪽에서 같은 조상 유래 구간을 물려받으면 생깁니다. 재조합으로 시간이 지날수록 이 구간은 잘게 쪼개지므로, 긴 ROH는 최근 근친, 짧은 ROH는 오래된 조상 유래를 시사합니다. 전체 ROH 길이를 상염색체 길이로 나눈 값이 F_{ROH} 로 근친계수 추정치입니다. 계산은 bcftools roh나 PLINK 같은 도구로 VCF에서 구할 수 있고, 최소 길이와 허용 이형접합 수 같은 파라미터에 민감합니다.

Q19. PSMC의 원리와 한계는?

PSMC는 단일 개체의 이배체 유전체에서 이형접합 위치의 분포를 이용해 과거 시점별 유효 개체군 크기(N_e)를 추정합니다. 한 개체 안에서 두 상동염색체가 합쳐지는(coalescence) 시점이 개체군 크기와 관련 있다는 원리입니다. 한계는 ① 고심도 필요 ② 최근 수천~수만 년 해상도 낮음 ③ 시간·크기를 실제 값으로 바꾸려면 돌연변이율과 세대시간 가정이 필요하고 그 불확실성이 큼 ④ 개체군 구조의 변화가 N_e 변화처럼 보일 수 있음 ⑤ 한 개체 결과를 집단 전체로 일반화하기 어려움입니다. 따라서 절대 연대보다는 상대적 추세와 다른 종과의 비교에 무게를 두겠습니다.

Q20. 변이 호출 후 필터링은 어떻게 하나요?

기본적으로 품질값(QUAL), 개체별 심도(DP) 하한·상한, 매핑 품질(MQ), 이대립(biallelic) SNP만 선택, 결측 비율 기준을 둡니다. 심도 상한은 반복서열·중복 영역에서 나오는 가짜 이형접합을 거르기 위해 필요합니다. 또 상염색체와 매핑이 모호한 영역은 제외하고 상염색체 위주로 지표를 계산합니다. 정확한 기준값은 데이터 분포를 보고 정하겠습니다.

Q21. 결과가 정책에 어떻게 활용될 수 있나요? 구체적으로.

예를 들어 지역 개체군 간 유전적 분화와 근친 정도가 확인되면 ① 어느 개체군이 유전적으로 더 위태로운지 우선 순위를 정하고 ② 서식지 연결(생태통로)의 필요성에 근거를 제공하고 ③ 복원 시 개체 이식·도입(유전적 구제)의 적합 개체군을 선택하는 데 쓸 수 있습니다. 다만 제 결과는 기초 자료이고 실제 정책 결정에는 생태·집단 모니터링과 함께 판단해야 합니다.

Q22. 석사 2년 안에 가능한 계획인가요? 일정은?

(예시/틀) 1학기: 수업, 리눅스·파이프라인 숙달, 선행 연구·데이터 정리. 2학기: 공개 데이터 처리·매핑·변이 호출·품질 평가. 3학기: 이형접합도·ROH·PSMC 분석, 결과 해석, 필요 시 확장 분석. 4학기: 논문 작성. 계산 자원은 랩 서버를 사용하겠습니다. 범위가 크면 1종·소수 개체에 집중하겠습니다.

Q23. 석사 이후 확장한다면 어떤 분석을 추가할 수 있나요?

① 유해 변이/유전 부하 추정 ② 여러 개체군 비교를 통한 집단 구조(PCA 등) ③ 같은 틀로 다른 멸종위기종 적용 ④ 유효 개체군 크기의 최근 변화 추정(다개체 데이터 기반) 등이 있습니다.

Q24. 마이크로새틀라이트나 mtDNA 같은 기존 방법 대비 전장 유전체의 장점은?

마이크로새틀라이트·mtDNA는 소수 마커라 개체 수가 적은 집단에서는 분산이 크고 유전체 전체의 변동(ROH, 유전 부하)을 보지 못합니다. 전장 유전체는 수백만 개 변이를 쓰므로 개체 수가 적어도 추정 정밀도가 높고 근친, 역사, 유전 부하를 한 번에 볼 수 있습니다. 비용이 크다는 점은 단점이지만, 이번 연구는 공개 데이터라 그 부담이 없습니다.

Q25. 성염색체나 반복서열은 어떻게 다루나요?

수컷의 X는 반수체라 이형접합도가 왜곡되므로 상염색체만 대상으로 합니다. 참조의 어느 스캐폴드가 성염색체 인지는 근연종(소·양) 참조와의 상동성으로 확인하겠습니다. 반복서열은 매핑이 불안정해 필터링하거나 낮은 매핑품질 영역을 제외합니다.

D. 압박·약점 질문

Q26. 나이가 있고 연구 경력이 짧는데 이 분야에서 따라갈 수 있나요?

늦게 시작했지만 그만큼 이유가 분명합니다. 석사 과정은 가진 역량(데이터 분석, 글쓰기, 일정 관리)으로 보완하며 뒤처지는 부분은 더 시간을 들여 채우겠습니다. 이미 [독학한 내용]으로 기초를 쌓고 있습니다.

Q27. 연구실에서 정해 준 주제가 본인 계획과 다르면?

제 계획은 제가 가장 하고 싶은 방향이지만 랩의 연구 방향과 지도교수님의 판단이 우선이라고 생각합니다. 랩에서 진행 중인 프로젝트(예: 가축 유전체)를 맡게 되어도 분석 방법론은 공통이므로 열심히 배우고, 제 관심은 그 위에서 이어 가겠습니다.

Q28. 연구하면서 가장 힘들었던 경험과 극복 방법은?

(본인 경험: 산발 논문의 데이터 전처리·검증, 심사 코멘트 대응 등을 구체적으로) STAR 구조(상황-과제-행동-결과)로 한 사례만 준비하세요.

Q29. 공개 데이터를 쓸 때 윤리나 인용 문제는?

데이터 원 출처 논문과 accession을 정확히 인용하고, 데이터 사용 조건(공개 라이선스, 사용 제한 여부)을 확인합니다. 분석 코드와 파라미터를 기록해 재현 가능하게 하겠습니다. 또한 멸종위기종의 정밀 위치 같은 민감 정보는 공개 범위를 주의하겠습니다.

Q30. 마지막으로 하고 싶은 말, 혹은 질문 있나요?

질문 예시(좋은 역질문): - "입학 후 첫 학기에 파이프라인 숙달을 위해 어떤 준비를 하면 좋을까요?" - "랩에서 보전유전체 관련 프로젝트가 진행 중인지, 공개 데이터 기반 연구가 석사 주제로 가능한지 궁금합니다." - "VGP 참여 랩으로서 새로 조립되는 참조유전체를 활용한 후속 분석 계획이 있으신가요?"

피해야 할 질문: 연봉·장학금만 묻기, 홈페이지에 있는 내용 묻기.

2. 개념·용어 정리 (까먹은 유전체학 복습용)

읽는 순서: 2.1 → 2.2 → 2.3(지원서 파이프라인) → 2.4(집단유전학 지표) → 2.5(보전유전학) → 2.7(산양 배경)

2.1 유전체학 기초

용어	한 줄 설명
유전체(genome)	한 생물이 가진 전체 DNA 염기서열
상염색체(autosome) / 성염색체	성에 관계없이 쌍으로 존재하는 염색체 / X·Y 등 성 결정 염색체
이배체(diploid)	염색체가 쌍(부모 각 1개)으로 존재. 같은 위치에 대립유전자가 2개
대립유전자(allele)	같은 위치(locus)의 서로 다른 서열 형태
동형접합(homozygous) / 이형접합(heterozygous)	두 대립유전자가 같음 / 다름
SNP	한 염기 차이 변이 (가장 흔한 분석 단위)
indel	삽입·결실 변이
변이(variant)	참조유전체와 다른 지점
참조유전체(reference genome)	비교 기준이 되는 대표 유전체 서열
어셈블리(assembly)	시퀀싱 조각을 이어붙여 유전체를 복원한 결과
contig / scaffold / 염색체 수준	끊김 없는 조각 / contig를 연결한 것 / 염색체 전체 단위로 연결된 최고 수준 (Hi-C 등으로)
N50	어셈블리 연속성 지표(클수록 좋음)
BUSCO	어셈블리 완전성 평가 (보존 유전자가 얼마나 온전히 있나)
주석(annotation)	유전체에서 유전자 위치·기능을 표시하는 작업
VGP (Vertebrate Genomes Project)	모든 척추동물 종의 고품질 참조유전체를 만드는 국제 프로젝트

2.2 시퀀싱·데이터 형식

- 차세대 시퀀싱(NGS, Illumina): 짧은 리드(보통 100~150bp)를 대량 생성. 재서열분석(resequencing)에 가장 흔함
- 롱리드(PacBio HiFi, Nanopore): 긴 리드. 참조유전체 구축(de novo)에 주로 사용
- 재서열분석(resequencing): 이미 참조가 있는 종의 개체를 시퀀싱해 참조와 비교 (이번 계획이 이것)
- 심도/커버리지(depth, x): 유전체의 각 위치를 평균 몇 번 읽었는가. 10x면 평균 10번. 이형접합 호출의 신뢰도에 직결

- FASTQ: 리드 + 염기 품질(Phred score). 원본 데이터
- BAM/SAM: 리드를 참조에 정렬한 결과
- VCF: 변이 목록(위치, 참조/변이 염기, 개체별 유전자형, 품질)
- Phred 품질점수: $Q30 = \text{오류 확률 } 0.1\%$
- NCBI SRA / BioProject / accession: 공개 시퀀싱 데이터 저장소. SRR... 번호로 다운로드 (prefetch, fasterq-dump)

2.3 지원서 파이프라인 단계별 의미

SRA 다운로드 → FASTQ

- fastp (품질관리)
- BWA-MEM (참조에 정렬) → BAM
- samtools sort/index, 중복 제거(markdup)
- bcftools mpileup | bcftools call (변이 호출) → VCF
- 필터링
- 이형접합도 / ROH / PSMC

1. fastp: 어댑터 서열 제거, 저품질 염기·짧은 리드 제거, QC 리포트 생성
2. BWA-MEM: 리드를 참조유전체의 어느 위치에서 왔는지 찾아 정렬. 출력은 SAM → samtools로 BAM 변환·정렬·인덱싱
3. 중복 제거(PCR duplicates): 같은 DNA 조각이 PCR로 여러 번 읽힌 것을 제거. 안 하면 변이 호출이 왜곡
4. mapping 품질 확인: 매핑률, 평균 심도(예: mosdepth, samtools flagstat)
5. bcftools mpileup / call: 각 위치에서 정렬된 염기들을 모아 유전자형을 확률적으로 판정
6. 필터링: QUAL, DP(너무 낮거나 높은 곳 제외), MQ, 이대립 SNP만, 상염색체 제외
7. 이형접합도 계산: (이형접합 SNP 수 ÷ 분석 가능한(callable) 상염색체 염기 수). 분모가 중요 — 변이가 있는 곳만이 아니라 "판정 가능했던 전체 염기 수"로 나눠야 함
8. ROH: 이형접합이 없는 연속 구간 탐지 (bcftools roh, PLINK --homozyg)
9. PSMC: 한 개체의 diploid 서열로 과거 N_e 추정 (아래 2.4)

2.4 집단유전학 핵심 개념

하디-바인베르크 평형(HWE) 대립유전자 빈도 p , $q(p+q=1)$ 일 때 유전자형 빈도 = $p^2 : 2pq : q^2$. 임의교배, 큰 개체군, 선택·돌연변이·이동 없음일 때 성립. 이 가정이 깨지는 정도로 근친·구조를 알 수 있음.

유전자 부동(genetic drift) 작은 개체군에서 대립유전자 빈도가 우연히 변하는 현상. 시간이 지나면 한 대립유전자만 남음(고정, fixation) → 다양성 감소.

유효 개체군 크기(N_e) 유전적으로 현재 개체군과 같은 정도의 부동을 보이는 이상적 개체군의 크기. 실제 개체수(N)보다 보통 훨씬 작음(성비 불균형, 번식 개체 수, 세대 간 변동 등). 보전유전학의 핵심 지표.

병목(bottleneck) / 창시자 효과(founder effect) 개체군이 급격히 줄거나 소수 개체에서 시작된 경우 다양성 급감.

이형접합도 - 관찰 이형접합도(H_o): 실제 개체가 이형접합인 비율 - 기대 이형접합도($H_e = 2pq$) - 유전체 전체 이형접합도: 개체당 염기 수 대비 이형접합 SNP 비율 (예: 1,000bp당 몇 개). 종마다 크게 다르며 멸종위기종은 매우 낮은 경향 - 뉴클레오타이드 다양성(π): 집단 내 임의의 두 서열 간 평균 차이

근친계수(F) 두 대립유전자가 공통 조상에서 유래해 같을(IBD) 확률. $F_{ROH} = (ROH \text{ 총 길이}) / (\text{상염색체 길이})$ 로 유전체 수준에서 추정 가능.

ROH 길이와 시간 재조합으로 IBD 구간은 세대마다 짧아짐. 평균 길이는 대략 $100/(2g)$ cM (g =공통 조상까지의 세대 수)로 설명됨. 즉 긴 ROH → 최근 근친, 짧은 ROH → 먼 과거의 조상. 연구에서는 길이 구간(예: <1Mb, 1~5Mb, >5Mb)으로 나눠 보고하는 경우가 많음.

PSMC (Pairwise Sequentially Markovian Coalescent; Li & Durbin 2011) - 입력: 한 개체의 diploid 유전체 (이형접합 위치 패턴) - 원리: 유전체를 구간(bin, 보통 100bp)으로 나누어 각 구간에 이형접합이 있는지(1)/없는지(0)를 기록. 재조합으로 인접 구간의 조상(coalescent time)이 달라지는 것을 은닉 마르코프 모형으로 추정해 시간별 Ne를 복원 - 시간·크기 스케일링: 모델은 $\theta=4Ne\mu$ 같은 상대 값만 줌. 실제 연도/개체 수로 바꾸려면 돌연변이율(μ)과 세대시간(g)이 필요 - 해석 주의: 최근(수천 년) 해상도 낮음, 구조 있는 집단은 Ne 변화로 오인될 수 있음, 고심도(약 $18\times$) 필요, bootstrap으로 신뢰구간 확인 - 대안: MSMC2, SMC++, Stairway Plot (다개체 활용)

연관불평형(LD) 인접한 변이가 함께 유전되는 정도. 재조합과 Ne에 영향받음. LD 기반 Ne 추정도 있음(예: GONE).

집단 구조 분석 PCA, ADMIXTURE(가상의 조상집단 수 K를 가정해 개체의 조상 비율 추정), Fst(집단 간 분화 정도), 계통수.

2.5 보전유전학 핵심 개념

개념	설명
근친 약세(inbreeding depression)	동형접합 증가로 해로운 열성 변이가 발현되어 생존·번식 감소
유전 부하(genetic load)	해로운 변이가 집단 적합도에 주는 부담. <i>masked</i> (이형접합 상태로 숨음) vs <i>realized</i> (동형접합으로 발현)로 구분
퍼징(purging)	근친이 지속되면 강하게 해로운 변이가 선택으로 제거되는 현상. 제한적이며 약한 유해 변이는 오히려 고정될 수 있음
유전적 구제(genetic rescue)	다른 개체군의 개체를 도입해 유전다양성·적합도를 회복
이계교배 약세(outbreeding depression)	지나치게 다른 집단 간 교배로 적합도가 떨어지는 것 (유전적 구제 시 고려)
서식지 단편화(fragmentation)	서식지가 쪼개져 이동·유전자 흐름이 차단 → 고립·드리프트
보전 단위(ESU/MU)	진화적 의미 단위 / 관리 단위
50/500 → 100/1000 규칙	단기 근친 방지에 $Ne \geq 50(100)$, 장기 진화 잠재력에 $Ne \geq 500(1000)$ 이 필요하다는 경험 법칙

이형접합도 낮음 ≠ 반드시 위험: 오래 작게 유지된 집단은 유해 변이가 제거되어 있을 수 있음. 반면 최근 급감한 집단은 아직 다양성이 남아도 곧 근친이 폭증할 수 있음. 그래서 ROH 길이 분포와 PSMC, 유전 부하를 같이 봅니다.

2.6 참조유전체 편향 (reference bias)

- 참조와 서열이 많이 다른 리드는 매핑이 안 되거나 낮게 평가됨 → 다양한 영역에서 변이가 과소추정
- 참조가 먼 종이면 반복·중복 영역에서 잘못된 정렬로 가짜 이형접합이 생길 수 있음
- 계통적으로 가까운 참조일수록 이 문제가 완화
- 점검 지표: 매핑률, 심도 분포, 이상치 영역, 알려진 근연종 지표와의 비교

2.7 산양 배경 (지원서에서 쓴 내용)

- 학명 *Naemorhedus caudatus* (긴꼬리고랄, 한국 산양), 소과(Bovidae) 염소아과
- 멸종위기 야생생물 I급, 천연기념물 제217호 (지원서 기재)
- 설악산·오대산 등 백두대간 일대 서식, 서식지 단절로 고립 우려 (지원서 기재, 구체적인 서식지·개체수는 최신 자료 확인)
- 참조: 같은 속 히말라야산양 *N. goral* 염색체 수준 참조유전체(2024, 지원서 기재) — 출처 직접 확인 필수
- 근연종 정보: 소(*Bos taurus*), 양(*Ovis aries*) 참조유전체는 품질이 높아 상동성 확인에 쓸 수 있음

2.8 컴퓨팅 기초 (서버 경험 부족 보완용)

- 필수 명령: `ls cd pwd mkdir cp mv rm cat head tail less grep awk sed sort uniq wc cut`
- 원격: `ssh`, `scp/rsync`, `tmux` 또는 `screen` (세션 유지)
- 환경: `conda/mamba`로 도구 설치 (`conda install -c bioconda fastp bwa samtools bcftools`)
- 작업 스케줄러: SLURM(`sbatch`, `squeue`) — 랩 서버에서 많이 사용. 대용량 작업은 직접 로그인 노드에서 돌리지 않음
- 워크플로 관리: Snakemake, Nextflow — 재현성 있는 파이프라인
- 파이프 `|`와 리다이렉션 `>`: 도구를 연결하는 핵심 문법

2.9 용어 한영 대조표 (면접 중 영어 용어를 들었을 때)

한국어	English
재서열분석	resequencing
참조유전체	reference genome
변이 호출	variant calling
이형접합도	heterozygosity
동형접합 구간	runs of homozygosity (ROH)
유효 개체군 크기	effective population size (Ne)
유전자 부동	genetic drift
근친교배 약세	inbreeding depression
유전 부하	genetic load
병목	bottleneck
서식지 단편화	habitat fragmentation
유전적 구제	genetic rescue
심도	sequencing depth / coverage
매핑	mapping / alignment
합착(공조상) 시점	coalescence time
돌연변이율	mutation rate (μ)
세대시간	generation time

3. 이 계획에서 스스로 짚어 둘 약점과 대응

약점	이유	대응
개체 수·심도 불확실	아직 데이터 확인 전	지원서 문장대로 "확인 후 확정"을 일관되게. 가능하면 면접 전에 SRA 실제 확인
새로움이 약해 보일 수 있음	공개 데이터 재분석	"참조 변경으로 인한 해상도 개선 + 선행 연구에 없는 분석 추가"로 설명. 선행 논문 확인 필수
PSMC 전제(고심도)	저심도 데이터는 부적합	개체별 심도에 따라 분석 선택
근연종 참조도 편향 가능	같은 속이지만 별종	한계로 인정하고 점검 방법 제시
대상 종이 한 종뿐	일반화 어려움	"방법론 확장 가능성"으로 결론에서 언급한 점 활용
전환 경력	유전체 직접 경험 없음	소규모 파이프라인을 직접 돌려 본 경험 만들기

4. 1분 요약 카드 (면접 직전용)

- 나: 7년 직장인 → 생명과학 복수전공 → 산불 연구 2저자(데이터 분석) → 멸종위기종 유전체
- 연구: 산양의 공개 재서열 데이터를 가까운 새 참조(히말라야산양, 2024)에 재매핑 → 이형접합도·ROH로 근친, PSMC로 역사 → 복원 정책 기초 자료
- 왜 의미 있나: 새 시료 없이, 참조 편향을 줄여 정밀 분석 가능
- 핵심 한계: 개체 수·심도, 근연종 참조의 편향, PSMC의 μg 가정
- 왜 이 랩: VGP, 유전체 조립·집단유전학, 아프리카 소 연구에서 유사 분석 흐름
- 약점/보완: 서버·파이프라인 경험 부족 → 리눅스 독학, 소규모 파이프라인 직접 실행

5. 읽어 볼 자료 (서지는 검색으로 정확히 확인하세요)

1. Li H, Durbin R. *Inference of human population history from individual whole-genome sequences*. Nature 2011 — PSMC 원논문
2. Ceballos FC et al. *Runs of homozygosity: windows into population history and trait architecture*. Nat Rev Genet 2018 — ROH 개념 정리 (리뷰)
3. Rhie A et al. *Towards complete and error-free genome assemblies of all vertebrate species*. Nature 2021 — VGP
4. Bertorelle G et al. *Genetic load: genomic estimates and applications in non-model animals*. Nat Rev Genet 2022 — 유전 부하
5. 김희발 교수 연구실의 최근 논문(아프리카 토착 소 기원 논문 포함) — 초록과 방법(Methods) 위주로
6. 산양 재서열 데이터의 원 논문과 히말라야산양 참조유전체 원 논문/DB 페이지
7. 한국 산양 보전·복원 관련 국립공원공단/국립생태원 자료 (서식 현황, 복원 사업)
8. 교재: Frankham 등 *Introduction to Conservation Genetics* (핵심 챕터: 유전자 부동, Ne, 근친, 유전적 구제)

6. 학습 플랜 (남은 기간에 맞춰 조정)

우선순위 A (반드시, 면접 직전까지) 1. 2.3~2.5를 읽고 자기 연구계획을 빈 종이에 1장으로 그려 보기 (단계·입출력·왜 쓰는지) 2. 위 ⚠ 사실 체크리스트 확인 (SRA 데이터, 참조유전체, 선행 연구, 랩 논문) 3. Q12(연구계획 2분 설명)와 Q14, Q15, Q17~Q19 소리 내어 연습 (녹음해서 확인) 4. 산불 논문 복습 (Q7)

우선순위 B (여유가 있다면) 5. 작은 데이터로 파이프라인 한 번 직접 실행 (예: 박테리아 또는 단일 염색체 데이터로 `fastp→bwa→samtools→bcftools`). 실행 기록(스크린샷, 명령어)이 있으면 Q10, Q11 답이 훨씬 구체화됩니다 6. PSMC 원논문 초록·그림, Ceballos 2018 리뷰의 ROH 그림 보기 7. 랩 홈페이지의 논문·연구 주제 정리

우선순위 C 8. 영어 용어 대조(2.9) 훑기, 면접이 영어 질문을 포함할 가능성에 대비해 연구계획 영어 1분 요약 준비

면접 당일: 모르는 질문엔 "정확히는 아직 확인하지 못했습니다. 제가 이해한 바로는 …"처럼 아는 범위까지 말하고, 확인·학습하겠다는 태도로 마무리하세요. 지원서 내용을 과장해 방어하는 것이 가장 위험합니다.