

면접 답변 (구어체) + 용어 정리

본인이 쓴 답변을 반영한 버전(v2) · 뒤에 용어 정리 1.2부 · [] = 직접 확인해서 채울 부분 · 노란색 = 가장 중요

말하기 팁

- 외우지 말고 첫 문장 + 키워드만 기억하세요. 매번 똑같이 말할 필요 없습니다.
- 문장이 길어지면 끊어서, 숨 쉬고, 천천히. 면접관은 속도가 아니라 내용을 봅니다.
- 모르는 건 "아직 확인하지 못했는데, 제가 이해한 바로는..."으로 아는 데까지만 말하고 마무리하세요.
- []는 실제로 확인하거나 해본 것만 넣으세요. 안 해본 것을 말하면 꼬리질문에서 막힙니다.

A. 동기·배경

A1. 자기소개와 지원동기 (1분)

안녕하세요. 저는 고등학교를 졸업하고 7년 정도 금융권이랑 마케팅 쪽에서 일하다가, 조금 늦은 나이에 대학에 들어갔습니다. 대학에서 생물학개론을 들었는데, 생명 현상이 너무 정교하고 신기해서 생명과학을 복수전공하게 됐어요. 그러다 자연과공생연구소에서 산불 발생 요인을 분석하는 논문에 2저자로 참여했는데, 그때 데이터를 분석하는 일이 정말 재미있다는 걸 알게 됐습니다. 그래서 이 역량으로 멸종위기종의 유전체 연구를 해보고 싶어서 지원했습니다. 특히 교수님 연구실이 VGP에도 참여하시고 다양한 종의 유전체를 분석해 오셔서, 제가 하고 싶은 연구랑 가장 잘 맞다고 생각했습니다.

A2. 왜 우리 연구실인가요?

교수님 연구실에서는 VGP에 참여하시고, 아프리카 소의 유전 기원을 밝히는 연구도 하시고, 독도에 사는 희귀한 기생 식물 초종용의 유전체도 분석하신 걸로 알고 있습니다. 저는 그중에서도 멸종위기나 희귀한 생물을 유전체로 연구하신 경험이 제 관심이랑 맞닿아 있다고 느꼈어요. 제가 해보려는 분석이 [소 논문에서 쓰신 방법]이랑 흐름이 비슷해서, 이 연구실에서 제대로 배울 수 있겠다고 생각했습니다. 그리고 제가 서버에서 분석해 본 경험이 아직 부족한데, 그 부분도 여기서 채우고 싶습니다.

A3. 7년 일하다 갑자기 생명과학이요? 확신은 어디서 나왔나요?

막연하게 좋아서 온 건 아니고요, 직접 해보면서 확인했습니다. 복수전공으로 공부해 보고, 시민과학으로 산림곤충이나 수달 조사도 하고, 연구소랑 수목원에서 실제로 일도 해봤는데, 힘들어도 계속하고 싶다는 생각이 들었어요. 마케팅 때 KPI 짜고 데이터 보던 경험도 지금 데이터 해석할 때 꽤 도움이 됩니다.

A4. 왜 생태나 산림이 아니라 유전체인가요?

저는 생명과학이라는 학문 자체를 좋아합니다. 수정이 시작되는 발생의 순간부터 생명체가 생명을 유지해 가는 과정까지, 알면 알수록 신비롭고 정교하더라고요. 어렵기도 하지만 그래서 더 재미있었습니다. 한편으로는 멸종위기종에 대한 특별한 마음이 있는데, 이런 미시적인 세계에 대한 관심이랑 멸종위기종에 대한 관심을 둘 다 연구할 수 있는 분야가 멸종위기종 유전체, 그러니까 보전유전체학이라고 생각했습니다. 그래서 오랫동안 열정을 가지고 깊이 파고들 수 있는 분야라고 느꼈습니다. 생태학적인 시각은 연구 결과를 현장이랑 연결할 때 계속 가져가겠습니다.

A5. 석사만 하실 건가요, 박사까지 하실 건가요?

박사까지 진지하게 고려하고 있습니다. 석사 과정은 박사를 가기 전에 기초를 다지는 시간이라고 생각하고, 독립적인 연구자가 되려면 박사 과정이 필요하다고 봅니다. 그래서 석사에 입학하게 되면 먼저 역량을 충분히 길러서 박사 과정까지 이어 가고 싶습니다. 물론 석사 과정 자체에 최선을 다하겠습니다.

참고: 지원서에는 "석사 후 취업(국립생태원·국립생물자원관)"도 쓰셨습니다. 면접에서는 박사 고려를 중심으로 말하되, "연구 기관에서 복원 연구를 하고 싶다"는 장기 목표는 같다고 이어 가면 일관됩니다.

B. 경험·역량

B1. 산불 논문에서 정확히 뭘 하셨나요?

2저자로 참여해서 연구 방법 구상, 데이터 수집이랑 전처리, 분석, 초고 작성, 시각화까지 맡았습니다. 산불이 났는지를 결과로 두고, 임도나 등산로, 산림경영 같은 인위적 요인이랑 임상 변수, 기상 변수를 설명변수로 골랐고요. 먼저 Random Forest랑 XGBoost를 돌려서 어떤 변수가 산불 발생이랑 관련이 깊은지 변수 기여도를 봤습니다. 그다음에 변수들끼리 너무 겹치는 건 VIF 점수를 보고 걸러냈고, 최종적으로 추린 변수로 로지스틱 회귀분석을 했습니다. 결과를 보면 임령이 높을수록, 그리고 습도가 높을수록 산불이 덜 났고, 침엽수림에서 산불이 더 나는 경향이 있었어요. 임도나 등산로는 가까울수록 산불이 억제되는 경향을 보였고, 숲아베기 같은 산림경영 변수는 통계적으로 유의하지 않아서 후속 연구가 필요하다고 정리했습니다. 가장 인상 깊었던 건 임령이 높을수록 산불이 억제된다는 결과였습니다.

아래 B1-1 ~ B1-6은 이 답변에서 이어질 수 있는 후속 질문입니다. 개념은 맨 뒤 "용어 정리 2부"에 쉽게 설명했습니다.

B1-1. Random Forest가 뭔가요?

결정나무를 여러 개 만들어서 그 결과를 모아서 판단하는 방법입니다. 나무마다 데이터와 변수를 조금씩 다르게 뽑아서 만들기 때문에 한 나무가 틀려도 전체로는 안정적이에요. 그리고 어떤 변수를 썼을 때 예측이 얼마나 좋아지는지를 보면 변수 기여도를 볼 수 있어서, 저는 어떤 변수가 산불이랑 관련이 깊은지 보려고 썼습니다.

B1-2. XGBoost는 Random Forest랑 뭐가 다른가요?

Random Forest는 나무를 따로따로 만들어서 합치는 거고, XGBoost는 나무를 차례대로 만드는데 앞 나무가 틀린 부분을 다음 나무가 보완하는 방식입니다. 보통 성능이 더 좋은 대신 설정값에 민감해서 과적합에 신경 써야 합니다.

B1-3. VIF가 뭐고 왜 걸러냈나요?

VIF는 변수끼리 얼마나 겹치는지 보는 지표입니다. 어떤 변수가 다른 변수들로 거의 설명되면 VIF가 높아지는데, 보통 5나 10 이상이면 문제가 있다고 봐요. 겹치는 변수가 같이 들어가면 회귀분석에서 계수가 불안정해지고 해석이 어려워져서, 높은 변수는 빼고 분석했습니다.

B1-4. 머신러닝을 돌리고 왜 또 로지스틱 회귀를 하셨나요?

머신러닝은 어떤 변수가 중요한지는 잘 알려주는데, 그 변수가 산불을 늘리는지 줄이는지 방향이랑 크기는 바로 해석하기가 어렵거든요. 그래서 중요한 변수를 추린 다음에 로지스틱 회귀로 방향이랑 크기를 해석했습니다. **[논문에서 실제로 이렇게 한 이유와 맞는지 확인하세요. 다르면 본인이 실제로 한 이유로 바꾸세요]**

B1-5. 임도나 등산로에 가까울수록 산불이 억제된다는 건 의외인데, 왜 그럴까요?

제가 이해하기로는 **[논문 논의에서 설명한 이유]** 때문입니다. 일반적으로 이런 결과는 길이 가까우면 사람이 빨리 발견하고 진화 인력이 접근하기 쉬워서 큰 산불로 번지는 걸 막는다는 식으로 해석하는 경우가 있습니다. 다만 인과관계라고 단정하기보다는 연관성으로 보고, 추가 연구가 필요하다고 생각합니다.

△ 위 해석은 일반적인 가능성입니다. 논문에 실제로 쓴 설명을 우선하세요.

B1-6. 임령이 높을수록 산불이 억제된 이유예요? 그리고 한계는요?

논문에서는 **[논문 논의의 설명]**으로 해석했습니다. 한계로는 산불 발생 여부만 본 거라 규모나 원인까지는 못 봤고, 숲아베기 같은 산림경영 변수는 유의하지 않아서 후속 연구가 필요하다는 점이 있습니다.

B2. 서버나 리눅스 경험은요?

솔직하게 말씀드리면 리눅스나 서버에서 분석을 직접 돌려본 경험은 아직 없습니다. 대신 Python으로 머신러닝이랑 시각화는 해봤고 GIS로 공간 데이터도 다뤄봤습니다. 리눅스는 지금 독학으로 기본 개념을 공부하고 있고요. 입학하면 랩에서 쓰는 파이프라인을 따라 하면서 배우고, 처음 한두 달 안에 공개 데이터 한 개체를 처음부터 끝까지 돌려서 결과를 재현해 보는 게 목표입니다.

솔직하게 말하는 게 가장 안전합니다. 시간이 되면 명령어 몇 개(ls, cd, grep, head, ssh)와 "서버에 접속해서 파일을 다루는 흐름"만 개념으로 알아 두세요.

B3. 활동이 많은데 연구에 집중할 수 있나요?

제가 했던 활동들은 결국 전부 생물 보전에 대한 내용이었습니니다. 생물다양성을 보전하고 싶은 마음이 활동으로 이어진 거라서, 연구랑 방향이 같습니다. 그리고 생물을 좋아하는 마음이 연구할 때 지치지 않게 해주는 동력이 될 거라고 생각해요. 연구하려면 체력도 중요하니까 가끔 숲이나 자연에 가서 같이 살아가는 생물들도 만나면서 재충전하고 체력도 관리하려고 합니다. 이런 것들이 연구에 방해가 되지 않도록 연구를 1순위로 두고 시간을 관리하겠습니다.

B4. 나이도 있고 연구 경력도 짧은데 따라갈 수 있겠어요?

나이가 있는 건 맞습니다. 그래도 배움은 죽을 때까지 계속 해야 하는 거라고 생각해요. 남들보다 조금 늦게 시작했지만, 제가 뭘 좋아하고 뭘 잘하고 뭘 부족한지를 객관적으로 알고 있고요. 부족한 부분은 보완하고, 여러 경험에서 얻은 노하우도 잘 활용해서 좋은 연구자가 되도록 노력하겠습니다.

C. 연구계획 (가장 중요)

C1. 연구계획을 2분 정도로 설명해 주세요. 문제 → 기획 → 방법(지표 3개) → 새로움 → 한계 → 조율

제가 하고 싶은 연구는 산양의 유전체를 다시 분석해서 근친 정도랑 유전적 다양성을 보는 겁니다. 산양은 서식지 단절이나 폭설 때문에 개체수 감소가 걱정되는 멸종위기 I급 종인데요. 2018년에 선행 연구가 있었는데, 한 개체를 27배 심도로 읽어서 양 유전체에 맞춰 분석했습니다. 그런데 양은 산양이랑 약 천만 년 전에 갈라진 다른 종이어서, 참조랑 차이가 대략 2% 정도 되는 반면 이형접합도는 0.1% 정도거든요. 그래서 참조 차이가 결과에 영향을 줄 수 있습니다. 마침 2024년에 같은 속인 히말라야산양의 염색체 수준 참조유전체가 나와서, 같은 공개 데이터를 더 가까운 참조에 다시 맞춰볼 수 있게 됐습니다.

방법은 이 데이터를 새 참조에 매핑해서 변이를 찾은 다음에, 세 가지를 봅니다. 이형접합도로 유전적 다양성을, ROH, 그러니까 동형접합이 길게 이어진 구간으로 근친 정도를, PSMC로 과거 개체군 크기의 변화를 봅니다. 이때 양 참조랑 새 참조 결과를 같은 조건으로 비교해서, 참조를 바꾸면 결과가 얼마나 달라지는지도 확인하려고 해요. 다만 공개된 전장 데이터가 한 개체라서 개체군 전체에 대한 결론은 어렵다는 걸 알고 있고, 세부 계획이랑 개체를 늘리는 방법은 교수님과 상의해서 정하고 싶습니다. 결과는 복원이나 관리 정책의 기초 자료로 쓸 수 있다고 생각합니다.

C2. 이미 2018년에 분석된 데이터인데, 새롭게 알 수 있는 게 뭔가요?

새로운 건 데이터가 아니라 분석 방식입니다. 첫째, 같은 데이터를 같은 조건으로 두 참조에 맞춰서 이형접합도랑 PSMC가 달라지는지 비교해요. 그러면 선행 연구 결과가 참조 때문에 치우쳤는지 직접 확인할 수 있습니다. 둘째, 선행 연구에 없었던 ROH 분석을 염색체 위치랑 같이 봐서 근친 정도를 확인합니다. 그리고 선행 연구들이 PSMC를 돌릴 때 돌연변이율이랑 세대시간을 서로 다르게 써서 결과를 바로 비교하기 어려운데, 이것도 통일해서 비교할 수 있습니다.

C3. 참조를 바꾸면 달라질 거라고 하셨는데, 어떻게 확인하고 뭐가 성공인가요?

같은 데이터를 같은 조건으로 두 참조에 맞춰서 이형접합도 값이랑 PSMC 곡선을 비교하려고 합니다. 차이가 나면 선행 결과가 참조 영향을 받았다는 뜻이고, 차이가 없으면 기존 결과가 믿을 만하다는 확인이 되니까, 어느 쪽이든 의미가 있다고 생각합니다.

C4. 94%가 이미 양에 매핑되는데 왜 가까운 참조가 필요하죠?

매핑률 94%는 읽히긴 읽혔다는 거지 정확하게 읽혔다는 뜻은 아니거든요. 양이랑 차이가 대략 2%인데 이형접합도는 0.1% 정도라서, 작은 오정렬도 영향을 줄 수 있습니다. 실제로 얼마나 영향이 있는지는 두 참조를 비교해서 확인하겠습니다.

C5. 개체가 하나뿐인데 뭘 결론 낼 수 있나요?

맞습니다, 개체가 하나라서 개체군 수준 결론은 못 내립니다. 그래서 이 연구는 그 개체의 유전체 상태랑 방법 비교까지를 범위로 보고 있어요. 그리고 한국 산양은 북부랑 남부가 구분된다는 연구도 있어서, 한 개체가 전체를 대표하지 못한다는 점도 알고 있습니다. 보관 시료나 협력 기관으로 개체를 늘리는 건 교수님과 상의하고 싶고, 어려우면 수달 같은 다른 종으로 바꾸는 것도 생각하고 있습니다.

C6. 공개 데이터가 부족하면 어떻게 하시겠어요?

심도가 충분한 개체, 이 경우 27배 개체에만 PSMC를 적용하고요, 심도가 낮은 데이터는 낮은 심도에서도 쓸 수 있는 방법을 찾아보거나 집단 수준 분석에만 쓰려고 합니다. 데이터가 정말 부족하면 같은 방식을 수달 같은 다른 멸종위기 종에 적용하겠습니다.

C7. 이형접합도가 낮으면 곧 위험한 건가요?

이형접합도가 낮다고 무조건 위험한 건 아니에요. 오랫동안 작은 집단이었던 종은 해로운 변이가 이미 걸러졌을 수도 있고, 반대로 최근에 급격히 줄어든 집단은 아직 이형접합도가 남아 있어도 앞으로 근친이 빨리 늘 수 있거든요. 그래서 ROH 길이랑 PSMC를 같이 봐야 한다고 생각하고, 한 개체의 이형접합도만으로 근친이라고 단정하지는 않겠습니다.

C8. ROH가 뭐고 PSMC는 어떤 원리인가요?

ROH는 두 상동염색체가 같은 대립유전자로 짝 이어지는 구간인데요, 시간이 지나면 재조합으로 잘게 쪼개지니까 긴 ROH는 최근 근친, 짧은 ROH는 오래된 조상을 뜻합니다. PSMC는 한 개체의 이형접합 위치 분포로 과거 개체군 크기를 추정하는 건데, 시간 축이 돌연변이율이랑 세대시간에 따라 달라지고, 최근 해상도가 낮다는 한계가 있습니다.

C9. 성염색체나 참조 품질은 어떻게 하실 건가요?

참조 개체가 암컷이라 Y는 없고, X는 소나 무스콕이랑 비교해서 찾았다고 논문에 나와 있습니다. 저는 X를 빼고 상염색체만 계산할 생각입니다. 참조 품질은 스캐폴드 N50이 106 Mb 정도로 염색체 수준이고 BUSCO도 97% 가까이 되는데, contig N50이 3.7 Mb로 작은 편이라 contig 경계 근처는 조심해서 보겠습니다.

C10. 참조가 중국 개체인데, 한국 산양이랑 얼마나 달라요?

같은 속이지만 다른 종이라 차이는 있습니다. 그래도 양보다는 훨씬 가깝고요. 얼마나 차이 나는지는 매핑률이랑 두 참조 비교로 점검하겠습니다. 정확한 분기 시점은 제가 아직 확인하지 못했습니다.

C11. 제가 다른 주제를 제안하면요?

제 계획은 초안이라서 교수님 의견이 우선이라고 생각합니다. 매핑하고 변이 찾고 집단유전학 지표 보는 흐름은 어떤 종을 해도 비슷해서, 다른 주제를 주셔도 열심히 배우겠습니다. 제 관심은 그 위에서 이어가겠습니다.

C12. 수달에도 관심 있으시던데 왜 산양인가요?

둘 다 관심이 있습니다. 수달은 시민과학으로 현장에서 직접 접해 봤고요, 산양은 공개 데이터랑 가까운 참조가 있어서 새 시료 없이 시작할 수 있어서 먼저 골랐습니다. 수달도 같은 종 참조랑 동아시아 20개체 데이터가 공개돼 있어서, 한국 개체 자료를 구할 수 있으면 확장해 보고 싶습니다. 어느 쪽이 좋을지는 교수님과 상의하고 싶습니다.

C13. 결과가 정책에 어떻게 쓰이나요? 2년 안에 가능한가요?

근친 정도랑 개체군 역사를 숫자로 보여주면, 서식지를 연결하거나 복원할 때 어떤 개체를 들여올지 논의하는 기초 자료가 됩니다. 월악산 복원 때 어느 집단 개체를 옮길지가 실제로 쟁점이었던 걸로 알고 있어요. 일정은 1학기에 수업이랑 파이프라인 익히기, 2학기에 데이터 처리랑 매핑, 3학기에 분석이랑 해석, 4학기에 논문 쓰기로 생각하고 있고, 범위가 크면 한 종, 적은 개체에 집중하겠습니다.

D. 기타

D1. 요즘 이 분야 최신 이슈 중에 관심 있게 보신 게 있나요?

솔직히 전부 따라가지는 못하는데요, 제가 이해하고 있는 건 두 가지입니다. 하나는 염색체 수준의 참조유전체가 계속 새로 나오고 있다는 거고, 이번 제 계획도 거기서 출발했습니다. 다른 하나는 보전유전체 쪽에서 이형접합도만 보지 않고 유전 부하나 유전적 구제까지 같이 보는 흐름입니다. 교수님 랩 논문은 초종용 논문을 봤고요, 아직 더 읽어 봐야 한다고 생각합니다. 입학하면 더 깊이 공부하겠습니다.

△ 말한 건 꼬리질문이 올 수 있으니 용어 정리 1부의 "유전 부하·유전적 구제·참조유전체 품질" 항목을 읽어 두세요. 초종용 논문은 "어떤 분석을 했는지" 한 문장은 말할 수 있게 확인하세요.

D2. 마지막으로 하고 싶은 말이나 질문 있으세요?

입학 전에 미리 준비하면 좋은 게 있을까요? 그리고 공개 데이터를 기반으로 한 보전유전체 연구가 석사 주제로 가능한지도 궁금합니다. 오늘 시간 내주셔서 감사합니다.

모르는 질문이 나왔을 때

- "정확히는 아직 확인하지 못했는데, 제가 이해한 바로는 ~입니다."
- "그 부분은 제가 아직 부족해서, 입학하면 확인해서 배우겠습니다."
- "교수님 의견을 듣고 계획을 조정하고 싶습니다."

용어 정리 1부: 유전체학 (까먹었을 때 복습용)

먼저 비유로 잡기

- 참조유전체 = 정답 "지도". 새로 읽은 DNA 조각을 이 지도에 맞춰 붙여서 차이를 찾는 게 재서열분석
- 리드 = 찢어진 책의 문장 조각 / 심도(27x) = 같은 부분을 평균 27번 읽었다는 뜻
- 변이 호출 = 지도와 다른 글자 찾기 / 이형접합도 = 엄마·아빠에게서 받은 글자가 서로 다른 자리의 비율
- ROH = 엄마·아빠 DNA가 똑같은 구간이 길게 이어진 곳 (혈연이 가까운 부모에서 나온 흔적)
- PSMC = 한 개체의 DNA 안에 남아 있는 조상의 "개체수 기록"을 거꾸로 읽는 방법

1) 기본 개념

용어	쉬운 설명
DNA / 유전자 / 유전체	DNA는 4개 글자(A·T·G·C)로 쓴 정보. 유전자는 그중 단백질을 만드는 정보가 있는 부분(산양 참조 논문에서 주석된 유전자 약 2만 개). 유전체는 한 생물의 DNA 전체(산양 약 2.6 Gb = 26억 글자)

염색체	DNA가 포장된 단위. 히말라야산양 참조는 28개 pseudochromosome으로 정렬됨(논문 기준)
상염색체 / 성염색체	성별과 상관없이 쌍으로 있는 염색체 / X·Y. 수컷의 X는 하나뿐이라 이형접합도가 왜곡 → 이형접합도·ROH는 상염색체만 계산
대립유전자(allele)	같은 자리(locus)에 있는 서로 다른 글자. 엄마·아빠에게서 하나씩 받음
동형접합 / 이형접합	받은 두 글자가 같으면 동형, 다르면 이형
SNP / indel / 변이	한 글자 차이 / 글자의 삽입·삭제 / 참조와 다른 모든 자리
돌연변이율(μ), 세대시간(g)	한 세대에 글자가 바뀌는 비율 / 부모 → 자식까지 걸리는 시간. PSMC에서 연도로 환산할 때 꼭 필요

2) 시퀀싱·데이터·참조유전체

용어	쉬운 설명
NGS / 숏리드 / 롱리드	DNA를 잘게 잘라 대량으로 읽는 기술. 숏리드(Illumina, 100~150 글자)는 정확하고 재서열에 적합, 롱리드(PacBio, Nanopore)는 길게 읽어 참조 구축(조립)에 유리
재서열분석(resequencing) vs de novo	이미 참조가 있는 종을 읽어서 비교(이번 계획) vs 참조 자체를 새로 만들(히말라야산양 논문)
심도(depth, coverage)	각 위치를 평균 몇 번 읽었는가. 낮으면 이형접합을 놓침. PSMC는 대략 18x 이상 권장, 27x는 충분
FASTQ / BAM / VCF	읽은 원본(글자+품질) / 참조에 맞춰 정렬한 결과 / 찾은 변이 목록
Phred 품질(Q30)	글자 하나가 틀렸을 확률. $Q30 = 0.1\%$
조립, contig, scaffold	읽은 조각을 이어 붙여 유전체를 복원. contig = 끊김 없이 이어진 조각, scaffold = contig를 순서·방향으로 연결(사이는 N으로 채움)
N50	조각을 긴 순서로 더했을 때 전체의 50%에 도달하는 지점의 길이. 클수록 연속성이 좋음. 이번 참조: contig N50 3.7 Mb, scaffold N50 106.66 Mb
BUSCO	모든 포유류가 가진 보존 유전자가 얼마나 온전히 있는지로 완전성 평가 (이번 참조 96.9%)
Hi-C / 염색체 수준	염색체 안에서 가까운 DNA 조각의 접촉 정보를 이용해 scaffold를 염색체 단위로 정렬. "염색체 수준 참조"가 이것
VGP	Vertebrate Genomes Project. 모든 척추동물의 고품질 참조유전체를 만드는 국제 프로젝트(교수님 랩 참여)
SRA / BioProject / BioSample	NCBI의 공개 시퀀싱 데이터 저장소 / 연구 단위 번호(PRJNA···) / 시료 단위 번호(SAMN···)

3) 이번 연구의 분석 단계

단계	하는 일과 면접용 한 문장
① 데이터 확보	SRA에서 내려받기. "공개된 산양 재서열 데이터(PRJNA361026)를 사용합니다."
② fastp	어댑터 서열·저품질 염기·짧은 리드 제거. "오류가 많은 구간을 걸러내는 품질관리입니다."
③ BWA-MEM	리드가 참조의 어디에서 왔는지 찾아 정렬. "지도에 조각을 맞춰 붙이는 단계입니다."
④ 정렬·중복 제거	samtools로 BAM 정렬, PCR로 복제된 중복 리드 제거
⑤ bcftools 변이 호출	각 위치에서 정렬된 글자를 모아 유전자형 판정 → VCF. 이후 QUAL·심도(DP)·MQ 등으로 필터링
⑥ 이형접합도	(이형접합 SNP 수) ÷ (판정 가능했던 상염색체 전체 글자 수). 선행 연구 값 0.00113(= 약 0.1%)
⑦ ROH	이형접합이 없는 연속 구간 탐지(bcftools roh, PLINK). $F_{\text{ROH}} = \text{ROH 총 길이} \div \text{상염색체 길이}$
⑧ PSMC	한 개체의 이형접합 위치 분포로 시점별 과거 개체군 크기(N_e) 추정

4) 집단유전학

용어	쉬운 설명
하디-바인베르크 평형	무작위 교배·큰 집단·선택 없음 등이면 대립유전자 빈도 p , q 에서 유전자형 비율이 $p^2 : 2pq : q^2$ 로 유지. 깨지는 정도로 근친·집단 구조를 추정
유전자 부동(drift)	작은 집단에서 대립유전자 빈도가 우연히 변하는 현상 → 다양성 감소
유효 개체군 크기(N_e)	유전적으로 현재 집단과 같은 정도의 부동을 보이는 이상적 집단의 크기. 실제 개체수보다 보통 작음
병목 / 창시자 효과	집단이 급격히 줄었거나 소수에서 시작해 다양성이 크게 줄어든 상태
이형접합도(H_o/H_e), π	실제 이형접합 비율 / 기대 비율 / 집단 안 두 서열의 평균 차이. 선행 연구 산양 0.00113
근친계수(F), F_{ROH}	두 대립유전자가 같은 조상에서 온 확률. ROH로 유전체 수준에서 추정
ROH 길이	재조합으로 시간이 지나면 쪼개져 짧아짐 → 긴 ROH = 최근 근친, 짧은 ROH = 오래된 조상
PSMC (Li & Durbin 2011)	한계: 고심도 필요, 최근 수천~수만 년 해상도 낮음, 시간축이 μg 가정에 비례, 집단 구조가 N_e 변화로 보일 수 있음
F_{st} / AMOVA / 하플로타입	집단 간 유전적 분화 정도(0~1) / 변이를 집단 간·집단 내로 나누는 분석 / 한 DNA 조각(mtDNA)의 서열 유형. 전수원 논문: F_{st} 0.282, 집단 간 28.2%
mtDNA control region	미토콘드리아 DNA(모계 유전)의 변이가 큰 부위. 한 부위만 보므로 근친·유전 부하는 알 수 없음

5) 보전유전학

용어	쉬운 설명
근친 약세	동형접합이 늘어 해로운 열성 변이가 발현 → 생존·번식 저하
유전 부하(genetic load)	해로운 변이가 집단 적합도에 주는 부담. 숨어 있는 부하(이형접합) vs 발현되는 부하(동형접합)
퍼징(purging)	근친이 오래 지속되면 강하게 해로운 변이가 선택으로 제거되는 현상. 그래서 이형접합도가 낮다고 무조건 위험하지는 않음
유전적 구제 / 이계교배 억제	다른 집단 개체를 들여 다양성을 회복 / 지나치게 다른 집단과 교배해 적합도가 떨어지는 것(구제 시 고려)
서식지 단편화	서식지가 쪼개져 이동·유전자 흐름이 막힘 → 고립·부동
관리 단위(MU)	유전적으로 구분되어 따로 관리해야 하는 집단 (전수원 논문: 북부/남부)
참조 편향	참조와 차이가 큰 리드는 매핑이 안 되거나 오정렬돼 이형접합도·변이가 왜곡. 가까운 참조일수록 완화. 산양: 양과 약 2%, 이형접합 약 0.1%

용어 정리 2부: 산불 논문 통계·머신러닝 개념

이 논문의 흐름: ① 변수 만들기 → ② RF·XGBoost로 중요한 변수 보기 → ③ VIF로 겹치는 변수 제거 → ④ 로지스틱 회귀로 방향·크기 해석

개념	쉬운 설명	면접용 한 줄
결정나무	"임령이 30년 이상인가? → 예/아니오"처럼 질문을 이어 가며 데이터를 나누는 스무고개 모델	RF·XGBoost의 기본 단위
Random Forest	결정나무를 수백 개 만들되, 나무마다 데이터와 변수를 조금씩 다르게 뽑아 만들고 결과를 모아(다수결·평균) 판단. 한 나무가 틀려도 전체는 안정적이고 과적합에 비교적 강함. 변수 중요도(그 변수를 쓰면 예측이 얼마나 좋아지나)를 줌	"나무를 여러 개 독립적으로 만들어 합치는 방법입니다."

XGBoost	부스팅 방식. 나무를 순서대로 만들면서 앞 나무가 틀린 부분(오차)을 다음 나무가 보완. 정규화(과적합 억제)가 들어 있고 성능이 좋지만 설정값(하이퍼파라미터)에 민감	"앞 모델의 실수를 다음 모델이 고쳐 가는 방식입니다."
RF vs XGBoost	RF = 병렬(따로 만들어 합침), XGBoost = 직렬(차례로 보완)	둘 다 비선형·변수 간 상호작용을 잡을 수 있음
변수 기여도(중요도)	그 변수가 예측에 얼마나 도움이 되는지의 크기. 한계: 방향(늘림/줄임)은 알려주지 않고, 서로 상관된 변수끼리는 중요도가 나뉘어 낮게 보일 수 있음	"그래서 방향 해석은 로지스틱 회귀로 했습니다."
다중공선성	설명변수끼리 서로 너무 닮은 상태(예: 기온과 증발량). 회귀 계수가 불안정해지고 해석이 어려움	VIF로 점검
VIF	분산팽창계수. 어떤 변수가 나머지 변수들로 얼마나 설명되는지. $VIF = 1 / (1 - R^2)$. 보통 5나 10 이상이면 문제로 보고 제거·통합	"변수끼리 겹치는 정도를 보는 지표입니다."
로지스틱 회귀	결과가 "예/아니오"(산불 발생 여부)일 때 확률을 설명변수로 설명하는 회귀. 계수의 부호 = 방향(+ 산불 증가, - 산불 감소). 계수에 exp를 취하면 오즈비(몇 배 더 발생하기 쉬운가). p값으로 통계적 유의성 확인	"임령이 높을수록 산불 가능성이 줄어드는 방향이었습니다."
통계적 유의성(p값)	우연히 이런 결과가 나올 가능성. 속아베기가 유의하지 않았다 = 효과가 있다/없다를 이 데이터로는 확신할 수 없다	"유의하지 않아서 후속 연구가 필요합니다."
과적합	훈련 데이터에는 잘 맞는데 새 데이터에는 못 맞히는 상태. 교차검증, 변수 줄이기, 정규화로 억제	[논문에서 쓴 검증 방식 확인]
교차검증 / AUC	데이터를 나눠 번갈아 훈련·검증해 성능 평가 / 발생·미발생을 얼마나 잘 구분하는지(1에 가까울수록 좋음, 0.5는 찍기 수준)	[논문의 성능 지표 확인]
상관 ≠ 인과	"가까울수록 억제"는 연관성이지만 원인이라고 단정할 수 없음	임도·등산로 결과를 말할 때 반드시 붙이기

논문에서 다시 확인할 것: ① 표본 단위(산불 발생 지점? 격자?) ② 산불 지점이 훨씬 적을 때의 불균형 처리 ③ 교차검증·AUC 값 ④ 임도·임령 결과에 대한 논문의 해석 문장. 이 네 가지를 읽어 두면 B1 후속 질문에 대부분 답할 수 있습니다.

영어 용어 (읽기용)

reference genome · resequencing · read · depth/coverage · variant calling · heterozygosity · runs of homozygosity (ROH) · effective population size (Ne)	genetic drift · bottleneck · inbreeding depression · genetic load · genetic rescue · reference bias · Random Forest · gradient boosting · variance inflation factor (VIF) · logistic regression · odds ratio
--	--